



项目批准号	32071464
申请代码	C2105
归口管理部门	
收件日期	



20240132071464

国家自然科学基金 资助项目结题/成果报告

资助类别：	面上项目		
亚类说明：			
附注说明：	大数据和深度学习的建模、算法与分析		
项目名称：	基于深度学习的玉米开花期基因转录调控区的功能变异研究		
负责人：	汪海	BRID：	03568.00.76087
电子邮件：	wanghai@cau.edu.cn	电话：	13718563200
依托单位：	中国农业大学		
联系人：	李聪颖	电话：	010-62733540
直接费用：	58.0000（万元）	执行年限：	2021.01-2024.12

填表日期： 2025年01月05日

国家自然科学基金委员会制（2023年）



项目摘要

中文摘要:

转录是作物基因组控制农艺性状的关键环节。然而,由于转录调控区的语法难以解读,给作物智能设计育种带来两大难题:第一,如何在重要基因的转录调控区精准发掘功能变异并创制新变异,以拓宽育种的遗传基础;第二,如何解析复杂性状背后的多基因遗传互作,以指导多基因不同表达量的精准组合。为了解决上述问题,在玉米中建立了“转录调控区序列—基因表达量”的深度学习模型;并以开花期基因GI1为例,实验验证了该模型能够有效发掘和创制功能变异。在此基础上,本项目拟针对10个主效玉米开花期基因,利用深度学习技术在表达调控区系统发掘和设计功能变异;利用基因编辑技术创制上述变异的不同组合并验证其田间表型效应;通过建立“开花期基因表达量—开花期表型”深度学习模型,阐明玉米主效开花期基因的遗传互作模式。本研究将通过多学科交叉融合,为玉米开花期的智能设计育种提供新理论、新技术、新种质,同时为其他性状和其他作物的遗传改良提供借鉴。

Abstract:

In crops, genomic sequence is the ultimate controller of agronomic traits, with transcription as a crucial intermediate step. However, as it is difficult to interpret the grammar in transcription regulatory regions, intelligent design of crops is hampered in two aspects: (1) How to precisely identify functional variants and also create novel variants in transcription regulatory regions of key genes, to broaden the genetic basis of crop breeding. (2) How to dissect the genetic interactions among multiple genes underlying complex traits, in order to combine various expression levels of multiple genes more efficiently. To solve these problems, we established in maize deep learning models to predict gene expression levels from DNA sequences in transcription regulatory regions. By wet experiments, we also showcase the notion that deep learning models can revolutionize functional variant discovery and design, using the flowering-controlling gene GI1 as an example. Based on these results, this project will (1) use the above-mentioned deep learning model to systematically identify functional variants in the transcription regulatory regions of 10 major flowering-controlling genes, and also design novel functional variants; (2) create various combinations of these variants by genome editing and test their effects in the field; (3) unravel the genetic interactions among the 10 flowering time-controlling genes, by establishing a deep learning model predicting flowering time from the expression levels of flowering time-controlling genes. This multi-disciplinary project will provide novel theoretical basis, technology and germplasm for the intelligent design of maize flowering time, and the methods developed will also be applicable to other traits and other crop species.

关键词 (用分号分开): 人工智能; 深度学习; 功能变异; 转录调控; 基因编辑

Keywords (separated by;): artificial intelligence; deep learning; functional variant; transcription regulation; gene editing



结题摘要

中文摘要（对项目的背景、主要研究内容、重要结果、关键数据及其科学意义等做简单概述）：

玉米开花期是决定玉米适应性的关键性状，直接决定玉米的纬度分布和耕种制度。本项目将深度学习和分子生物学技术交叉融合，针对10个主效玉米开花期基因，利用深度学习技术在表达调控区系统发掘和设计功能变异；利用基因编辑技术创制上述变异的不同组合并验证其田间表型效应；通过建立“开花期基因表达量-开花期表型”模型阐明玉米主效开花期基因的遗传互作模式。具体包括以下内容：（1）转录调控区DNA序列大模型的开发：利用17个植物物种的60万个基因以及6256套转录组数据开发了一个名为PhytoExpr的深度学习模型，为转录调控区单碱基分辨率的定量解析提供了技术基础。（2）高通量低成本转录组定量技术开发：本项目需要对大量样品进行转录组分析，而传统转录组建库技术成本高速度慢，难以满足项目需求。因此，我们开发了一种新型RNA建库技术QUIC-seq。该方法能在4小时内完成大量样本的处理，将单个样本建库成本降至6元。（3）主效开花期基因近端转录调控区功能变异的发掘：利用PhytoExpr模型扫描了10个主效开花期基因近端表达调控区的自然变异，从中系统发掘功能变异并开展功能验证，进而利用基因编辑技术创制上述功能变异的组合。（4）主效开花期基因近端转录调控区功能变异的创制：通过对PhytoExpr模型的多种算法解析，获得10个主效开花期基因转录调控区每个碱基对基因表达量的效应，发掘重要位点并开展功能验证，进而利用敲除编辑技术创制重要位点的变异组合。（5）开花期主效基因遗传互作的解析：对上述基因编辑植株获得的主效开花期基因表达量和开花期表型数据，建立“主效开花期基因表达量-开花期表型”的机器学习模型，该模型可用于指导玉米开花期智能设计中多基因的功能变异的精准组合。本项目为玉米开花期智能设计提供新方法和新种质，也为玉米复杂性状设计中的多基因功能变异精准组合提供理论指导。

Abstract (Brief description of research background, main methods, contributions, and research data):

Flowering time is an important adaptive trait of maize that directly determines the latitude and cropping system of maize production. This study integrates deep learning with molecular biology, to systemically identify and design functional cis-regulatory variants on 10 flowering time-controlling genes. Combinations of these functional variants are written into the maize genome by genome editing and their phenotypic effects are evaluated. We further model the genetic interaction among these variants by establishing a model that predict flowering time from the expression levels of the 10 edited genes. Several key achievements of this study include: (1) Development of a deep learning model (named PhytoExpr) to understand the syntax of cis-regulatory DNA sequences. The model was trained and tested on 0.6 million genes and 6256 RNA-Seq samples to enable the quantification of the impact of each nucleotide on gene expression. (2) Development of a new library preparation method for transcriptome sequencing (named QUIC-Seq). This method can process large numbers of samples within 4 hours, with a cost of only 6 yuan per sample. (3) Identification of functional cis-regulatory variants on flowering time-controlling genes. We used the PhytoExpr model to scan the proximal cis-regulatory regions of flowering time-controlling genes to identify functional variants among all natural variants. We also created their combinations by genome editing. (4) Create novel functional cis-regulatory variants for flowering time-controlling genes. By interpretation of the PhytoExpr model, we identified important nucleotides on the cis-regulatory regions of flowering time-controlling genes, and created their variants (including combinations of variants) by genome editing. (5) Dissection of the genetic interactions among the flowering time-controlling genes. Based on the genome editing lines mentioned above, we established a model to predict flowering time from expression levels of flowering time-controlling genes. This model can be used to design combinations of alleles on multiple loci to achieve desired flowering time. In conclusion, this study provides new



techniques and new germplasm for maize flowering time breeding, and also general guidelines on how to manipulate multiple loci to finetune a complex trait.

关键词（用分号分开）： 转录调控； 深度学习； 玉米； 开花期；

Keywords (separated by;): transcriptional regulation; deep learning; maize; flowering time;

NSFC-REPORT-2024



正文

《结题/成果报告》正文分为两个部分：**结题部分和成果部分**。请按照《结题/成果报告》填报说明及撰写要求填写。

（一）结题部分

1. 研究计划执行情况概述。

（1）按计划执行情况。

玉米开花期是决定玉米适应性的关键性状，直接决定玉米的纬度分布和耕种制度。本项目将深度学习和分子生物学技术交叉融合，针对 10 个主效玉米开花期基因，利用深度学习技术在表达调控区系统发掘和设计功能变异；利用基因编辑技术创制上述变异的不同组合并验证其田间表型效应；通过建立“开花期基因表达量-开花期表型”模型，阐明玉米主效开花期基因的遗传互作模式。本项目按照计划完成了任务，从理论基础和种质资源两方面创新了玉米开花期的智能设计。

（2）研究目标完成情况。

本项目的研究目标包括两方面：第一，利用深度学习模型，精准发掘和创制玉米主效开花期基因转录调控区的功能变异，为玉米开花期智能设计提供新方法和新种质；第二，利用机器学习模型解析玉米主效开花期基因的遗传互作，为玉米开花期智能设计中的多基因功能变异精准组合提供理论指导。上述目标均已完成。本项目发表期刊论文 4 篇、申请专利 1 项、获得软件著作权 2 项。另有 1 篇论文正在投稿中。

2. 研究工作主要进展、结果和影响。

（1）主要研究内容。

本项目针对玉米的开花期，利用深度学习技术在主效开花期基因的转录调控区系统发掘和创制功能变异，进而解析主效开花期基因的遗传互作，为开花期智能设计提供理论指导和种质资源。

（2）取得的主要研究进展、重要结果、关键数据等及其科学意义或应用前景。



（2.1）转录调控区 DNA 序列大模型的开发

前期研究中我们建立了从转录调控区 DNA 序列预测基因二元化表达量的深度学习模型。在此基础上，本研究利用 17 个植物物种（拟南芥、毛果杨、大豆、甜菜、蒺藜苜蓿、黄瓜、葡萄、番茄、土豆、谷子、狗尾草、玉米、高粱、二穗短柄草、水稻、小立碗藓、莱茵衣藻）的 60 万个基因以及 6256 套转录组数据，开发了一个名为 PhytoExpr 的深度学习模型。该模型以近端转录调控区 DNA 序列为输入，预测基因的中位数表达量以及该序列来自哪个物种。该模型通过大数据的训练解决了过拟合的问题，为转录调控区单碱基分辨率的定量解析提供了技术基础。

（2.2）高通量低成本转录组定量技术开发

本项目需要对大量样品进行转录组分析，而传统转录组建库技术成本高速度慢，难以满足项目需求。因此，我们开发了一种新型 RNA 建库技术：QUIC-seq。QUIC-seq 技术将 3'RNA-seq 建库技术和 RNA/DNA 杂合双链建库技术相融合，兼具二者的优点；省略了传统转录组建库流程中的 85℃ 反转录酶失活、Tn5 酶失活和 Bst3.0 酶补缺口步骤，简化了操作流程并降低了成本；在反转录引物中加入 UMI（Unique Molecular Identifier），显著提升基因表达定量的准确性；增加了 barcode 组合数，提升了单个测序通道可承载的样本数量，从而降低了后续的测序成本。该方法能在 4 小时内完成大量样本的处理，将单个样本建库成本降至 6 元。

（2.3）主效开花期基因近端转录调控区功能变异的发掘

利用 PhytoExpr 模型扫描了 10 个主效开花期基因（*ZmMADS69*、*ZCN8*、*ZmNF-YA3*、*ZmMADS1*、*ZmCOL3*、*ZmRap2.7*、*ZmCCT9*、*ZmCCT10*、*Gl1*、*ZmCCA1a*）近端表达调控区的自然变异，从中系统发掘功能变异；利用原生质体瞬时转化技术，验证候选功能变异是否影响基因的转录；进而利用先导编辑技术在自交系背景下创制候选功能变异的组合，并在北京和海南两个生态区进行连续两年的主效开花期基因表达量测定和开花期测定，获得控制基因转录和田间开花期表型的功能变异。

（2.4）主效开花期基因近端转录调控区功能变异的创制

通过对 PhytoExpr 模型的多种算法解析，获得 10 个主效开花期基因转录调控区每个碱基对基因表达量的效应，发掘重要位点；利用原生质体瞬时转化技术，



获得关键候选；进而利用敲除编辑技术在自交系背景下创制重要位点的变异组合，在北京和海南两个生态区进行连续两年的主效开花期基因表达量测定和开花期测定，验证获得影响基因转录和田间开花期表型的关键位点，同时实现新变异的创制。

(2.5) 开花期主效基因遗传互作的解析

对 2.3 和 2.4 中获得的主效开花期基因表达量和开花期表型数据，建立“主效开花期基因表达量—开花期表型”的机器学习模型，该模型可用于指导玉米开花期智能设计中多基因的功能变异的精准组合。

(2.6) 科学意义和应用前景

本项目利用深度学习模型，精准发掘和创制玉米主效开花期基因转录调控区的功能变异，为玉米开花期智能设计提供新方法和新种质；解析玉米主效开花期基因的遗传互作，为玉米开花期智能设计中的多基因功能变异精准组合提供理论指导。本项目通过基因编辑技术创制了提前或推迟玉米开花期的新变异位点，未来可以导入玉米主栽品种，用于纬度适应性改良；部分变异可以适用于缩短华北地区玉米品种的生育期，使其适宜于“冬小麦夏玉米”的生产方式，因此具有良好的应用前景。

3. 研究人员的合作与分工。

项目设计和管理：汪海

数据分析和建模：李天祎、刘红兵

基因编辑载体构建，基因编辑位点验证：滕守振、李云飞

基因表达量测定和田间开花期测定：许辉、石祥鹏、陈丰懿

转录组建库和测序数据分析：王丹、钱毅恒

功能变异在瞬时表达体系中的验证：潘玲玲

4. 国内外学术合作交流等情况。

本项目执行过程中获得了国内外多名专家学者的指导和帮助，包括美国康奈尔大学 Edward Buckler 教授、丹麦奥胡斯大学 Guillaume Ramstein 助理教授、北京大学现代农业研究院宋宝兴研究员、坦桑尼亚农业科学院 Revocatus Bahitwa



农业研究专员等。通过本项目的执行，与上述团队建立了紧密合作的关系。

5. 存在的问题、建议及其他需要说明的情况。

无

(二) 成果部分

1. 项目取得成果的总体情况。

本项目的成果包括：发表期刊论文 4 篇、申请专利 1 项、获得软件著作权 2 项。另有 1 篇论文仍在投稿中，因此未列出。

(1) 期刊论文

Shouzhen Teng; Dan Wang; Yiheng Qian; Revocatus Bahitwa; Jinghong Shao; Mingrui Suo; Mingchi Xu; Luyuan Yang; Tianyi Li; Qiuying Yu; **Hai Wang**; QUILC-seq: Quick ultra-affordable high-throughput convenient RNA sequencing, Plant Biotechnology Journal, 2024, 23(1): 281-283. 第一标注

Tianyi Li; Hui Xu; Shouzhen Teng; Mingrui Suo; Revocatus Bahitwa; Mingchi Xu; Yiheng Qian; Guillaume P. Ramstein; Baoxing Song; Edward S. Buckler; **Hai Wang**; Modeling 0.6 million genes for the rational design of functional cis-regulatory variants and de novo design of cis-regulatory sequences, Proceedings of the National Academy of Sciences, 2024, 121(26). 第二标注

汪海; 赖锦盛; 王海洋; 李新海; 作物智能设计育种--自然变异的智能组合和人工变异的智能创制, 中国农业科技导报, 2022, 24(6): 1-8. 第一标注

Hai Wang; Mengjiao Chen; Xin Wei; Rui Xia; Dong Pei; Xuehui Huang; Bin Han; Computational tools for plant genomics and breeding, Science China Life Sciences, 2024, 67(8): 1579-1590. 第二标注

(2) 专利

汪海; 滕守振; 王丹; 钱毅恒, 一种 RNA-Seq 建库的方法, 2024-06-20, 中国, CN202410796820.X.

(3) 软件著作权

汪海; 利用 stacked CNN 模型从转录调控序列预测基因表达量和物种的软件,



2023SR1632008, 原始取得, 全部权利, 2023-10-5.

汪海; 植物转录调控区 DNA 序列的半暴力设计和遗传算法设计软件,
2023SR1629858, 原始取得, 全部权利, 2023-10-5.

2. 项目成果转化及应用情况。

本项目通过基因编辑技术创制了提前或推迟玉米开花期的新变异位点, 未来可以导入玉米主栽品种, 用于纬度适应性改良; 部分变异也可以用于缩短华北地区玉米品种的生育期, 使其适宜于“冬小麦夏玉米”的生产方式, 因此具有良好的应用前景。

3. 人才培养情况。

本项目培养硕士生 2 人, 博士后 1 人

4. 其他需要说明的成果。

无

5. 项目成果科普性介绍或展示网站。

无



研究成果目录

项目负责人通过系统，从文献库中检索研究成果或者按要求格式自行填入。请按照期刊论文、会议论文、学术专著、专利、会议报告、标准、软件著作权、科研奖励、人才培养、成果转化的顺序列出，其它重要研究成果如标本库、科研仪器设备、共享数据库、获得领导人批示的重要报告或建议等，应重点说明研究成果的主要内容、学术贡献及应用前景等。

项目负责人不得将非本人或非参与者所取得的研究成果、与受资助项目无关的研究成果、未标注国家自然科学基金资助和项目批准号的论文以及取得时间早于项目资助期开始时间的研究成果列入报告中。发表的研究成果（包括专利），项目负责人和参与者均应如实注明得到国家自然科学基金项目资助和项目批准号，科学基金作为主要资助渠道或者发挥主要资助作用的，应当将自然科学基金作为第一顺序进行标注。

期刊论文

(1) Shouzhen Teng; Dan Wang; Yiheng Qian; Revocatus Bahitwa; Jinghong Shao; Mingrui Suo; Mingchi Xu; Luyuan Yang; Tianyi Li; Qiuying Yu; Hai Wang; [QUIC - seq: Quick ultra - affordable high - throughput convenient RNA sequencing](#), *Plant Biotechnology Journal*, 2024, 23(1): 281-283. 第一标注

(2) Tianyi Li; Hui Xu; Shouzhen Teng; Mingrui Suo; Revocatus Bahitwa; Mingchi Xu; Yiheng Qian; Guillaume P. Ramstein; Baoxing Song; Edward S. Buckler; Hai Wang; [Modeling 0.6 million genes for the rational design of functional cis-regulatory variants and de novo design of cis-regulatory sequences](#), *Proceedings of the National Academy of Sciences*, 2024, 121(26). 第二标注

(3) 汪海; 赖锦盛; 王海洋; 李新海; [作物智能设计育种--自然变异的智能组合和人工变异的智能创制](#), *中国农业科技导报*, 2022, 24(6): 1-8. 第一标注

(4) Hai Wang; Mengjiao Chen; Xin Wei; Rui Xia; Dong Pei; Xuehui Huang; Bin Han; [Computational tools for plant genomics and breeding](#), *Science China Life Sciences*, 2024, 67(8): 1579-1590. 第二标注

专利



- (1) 汪海; 滕守振; 王丹; 钱毅恒; 一种RNA-Seq建库的方法, 2024-06-20, 中国, CN202410796820.X.


软件著作权

- (1) 汪海; 利用stacked CNN模型从转录调控序列预测基因表达量和物种的软件, 2023SR1632008, 原始取得, 全部权利, 2023-10-5.
- (2) 汪海; 植物转录调控区DNA序列的半暴力设计和遗传算法设计软件, 2023SR1629858, 原始取得, 全部权利, 2023-10-5.

项目成果应用前景

本项目成果拟应用领域: 1、生物育种 2、基因编辑育种 3、合成生物学

预计在5年以内推广使用



附表：研究成果统计数据表（本表针对各种类型资助项目收集数据以便进行整体资助效果分析使用，并非要求每类项目都具有以下各类成果。）

[illegible]



国家自然科学基金项目资金决算表

项目批准号：32071464

项目负责人：汪海

金额单位：万元

序号	科目名称	预算数			累计支出数	结余数	结余占比
		批准预算	预算调整	调整后预算			
		(1)	(2)	(3) = (1) + (2)			
1	项目总经费	69.6000	0.0000	69.6000	-	-	1.92%
2	项目直接费用	58.0000	0.0000	58.0000	56.6652	1.3348	-
3	1、设备费	0.0000	8.5700	8.5700	8.5674	0.0026	-
4	其中：设备购置费	0.0000	8.5700	8.5700	8.5674	0.0026	-
5	2、业务费	38.1600	0.0000	38.1600	37.1564	1.0036	-
6	3、劳务费	19.8400	-8.5700	11.2700	10.9414	0.3286	-
7	项目间接费用	11.6000	0.0000	11.6000	-	-	-

注：1. 本表仅填列自然科学基金批准资助的项目经费决算情况，其他来源资金的经费决算情况不属于本表填报范围；
2. 本表中（1）、（3）、（5）、（6） 栏为系统自动生成，不需项目负责人填写；本表中（2） 栏填列预算调整数；本表中（4）栏填列项目的实际支出数；
3. 本表中第7行数值由系统自动生成，不需项目负责人填写；
4. 第7行“预算调整”栏请参照《国家自然科学基金预算制项目决算表编制说明》中有关要求填列。



决算说明书

（请按照《国家自然科学基金预算制项目决算表编制说明》等的有关要求，说明项目预算支出情况、预算调整情况、资金结余情况、合作研究外拨资金情况、单价50万元（含）以上的设备情况、资金管理和使用过程中的问题建议，以及其他需要说明的事项。）

一、预算支出情况：项目直接经费预算批复58.0000万元。具体情况如下：

项目直接费用：

1、设备费：8.5674万元，用于购置玉米果穗考种设备和数据存储设备。

2、业务费：37.1564万元。

（1）材料费：支出12.4926万元，用于支出DNA、RNA提取试剂盒等

（2）测试化验加工费：支出6.5587万元，用于支出引物合成、转录组测序等

（3）燃料动力费：支出10.9161万元，用于支付温室电费

（4）差旅/会议/国际合作与交流费：支出2.1903万元，用于支出往返实验基地费用等

（5）出版/文献/信息传播/知识产权事务费：支出1.4685万元，用于支付版面费等

（6）其他支出：支出3.5302万元

3、劳务费支出10.9414万元。

（1）劳务费：支出10.9414万元，用于支出田间管理费用

（2）专家咨询费：无

项目间接经费支出11.60万元。

二、预算调整：

本项目在执行过程中，因实验需要，预算设备费调增8.57万元，劳务费调减8.57万元。目前结余1.3348万元，其中设备费结余0.0026万元，业务费结余1.0036万元，劳务费结余0.3286万元，用于支付应付未付款项。



签字及审核意见表

项目负责人承诺：

我所承担的项目（编号：32071464 名称：基于深度学习的玉米开花期基因转录调控区的功能变异研究）结题报告内容真实，数据准确，未出现《国家科学技术保密规定》中列举的属于国家科学技术秘密范围的内容，不涉及敏感科技信息。在今后的研究工作中，如有与本项目相关的成果，将如实注明得到国家自然科学基金项目资助和项目批准号，并报送国家自然科学基金委员会。

项目负责人（签章）：

日期：

依托单位科研管理部门：	依托单位财务管理部门：	依托单位审查意见：
负责人（签章）：	负责人（签章）：	依托单位公章：
日期：	日期：	

科学处审核意见：

完成情况 综合评分 (划√)	优	良	中	差	负责人（签章）：

科学部核准意见（对重点项目等）：

负责人（签章）：

日期：

分管委领导意见（对重大项目等）：

委领导（签章）：

日期：