



项目批准号	82173625
申请代码	H3011
归口管理部门	
收件日期	



国家自然科学基金 资助项目结题/成果报告

资助类别：	面上项目		
亚类说明：			
附注说明：			
项目名称：	大数据背景下循证因果迁移学习的统计方法研究		
负责人：	薛付忠	BRID：	08838.00.77501
电子邮件：	xuefzh@sdu.edu.cn	电话：	13906405997
依托单位：	山东大学		
联系人：	孙婕	电话：	0531-88369277
直接费用：	55.0000（万元）	执行年限：	2022.01-2025.12

填表日期： 2026年01月08日

国家自然科学基金委员会制（2025年）



项目摘要

中文摘要:

在循证因果证据推断中, RCT是内部有效因果证据金标准, 但因试验样本非随机选择使其外部有效性及泛化外推力差; 而同质总体两样本MR是获取观察性因果关联证据公认方法, 但对异质总体其偏倚巨大。当今在获取处理/暴露X及结局Y时, 容易获得丰富协变量Z大数据。本项目融合迁移学习、因果推断和统计推断, 通过数据驱动学习或因果推论, 获取RCT及两样本MR设计的因果机制选择图。进而, 针对RCT“试验样本与目标人群样本均具备X、Y、Z”、“前者具备X, Y, Z而后者仅有Z”、“前者仅有X, Z而后者具备X, Y, Z”三种数据库情形, 创建从RCT试验样本到目标人群样本的X对Y平均及个性化因果效应迁移的统计模型, 为评估或预估RCT外部有效性和外推泛化力提供新方法。同时, 针对异质总体的两样本MR, 创立因果关联效应的迁移统计模型, 将其适用范围推广到异质人群情形。由此, 构建大数据背景下循证因果证据迁移学习的统计方法体系及软件包。

Abstract:

In the evidence-based causal inference, RCT is the gold standard of internal effective causal evidence, but its external validity and generalized external thrust are poor due to the non-random selection of trial samples. In the present, two-sample MR based on homogeneous populations is a widely acknowledged method to obtain observational causal association. However, if there is heterogeneity between populations, the estimation of causal effect will be biased. Nowadays, it is easy to obtain the enough information with covariates Z when we get the data of treatment/exposure X and outcome Y. In this project, transfer learning, causal inference and statistical inference are integrated to obtain the causal mechanism selection diagrams of RCTs and Two-sample MR designs through data-driven deep learning or causal inference methods. We consider three scenarios of databases in this project, which are samples both in RCT and the target population have the data X, Y, Z, the RCT has X, Y, Z while the target population only has Z, and the RCT has X, Z and the target population has X, Y, Z. In view of these scenarios, we perform a novel statistical model to evaluate the average and individual causal effect of X on Y by transferring causal effects calculated from the RCTs to the target population. This new method can help evaluate or predict the ability of external validity and generalization of RCT. At the same time, for the two sample MR based on heterogeneous population, we develop a statistical model to transfer causal effects. Therefore, we are going to construct the related statistical method system and R package of the evidence-based causal transfer learning under the background of big data.

关键词 (用分号分开): 因果推断; 统计推断; 迁移学习; 随机对照试验; 两样本孟德尔随机化

Keywords (separated by;): Causal inference; statistic inference; transfer learning; randomized controlled trial; Two-Sample MR



结题摘要

中文摘要（对项目的背景、主要研究内容、重要结果、关键数据及其科学意义等做简单概述）：

针对大数据背景下随机对照试验（RCT）证据难以直接向真实世界目标人群泛化，以及传统孟德尔随机化（MR）在异质性人群中因果推断失效的共性难题，本项目旨在构建一套完善的“循证因果迁移学习统计方法体系”。在理论方法层面，项目组首先确立了因果选择图理论框架，构建了涵盖“数据驱动”与“假设驱动”的RCT因果迁移统计推断模型，有效解决了效应修饰干扰与数据缺失下的外部有效性推断问题；同时，项目组突破了传统MR的同质性假设瓶颈，创新性地提出了基于迁移学习的Two-Sample MR方法（TLMR）及跨种族联邦遗传相关桥接模型（TEMR），并进一步开发了仅利用汇总数据即可重构复杂因果网络的结构学习算法（MRSL）与多中介分析方法（PSE-MR）。为支撑上述理论方法的验证与转化，项目依托山东省健康医疗大数据平台，深度融合多源异构数据，构建了包括慢性乙型肝炎、主动脉夹层、脑卒中及胆囊结石等在内的8个高质量专病纵向队列。基于该方法体系与数据库，项目组开展了广泛的实证研究，不仅从宏观环境层面揭示了绿色覆盖与癌症发病的因果关联，还从临床诊疗层面确证了肺癌机会性筛查的生存获益及内脏脂肪对肺部疾病的致病风险。本项目圆满完成了既定科研任务，共发表学术论文28篇（其中SCI收录13篇），申请发明专利3项、软著4项，并培养了博士后2名、博士研究生7名、硕士研究生15名。研究成果为解决多源异构大数据下的因果推断难题提供了关键的方法学工具，成功打通了循证医学证据向真实世界转化的技术路径。

Abstract (Brief description of research background, main methods, contributions, and research data):

To address the common challenges of randomised controlled trial (RCT) evidence being difficult to directly generalize to real-world target populations in the context of big data, and the failure of traditional Mendelian randomisation (MR) in causal inference within heterogeneous populations, this project aims to establish a comprehensive "evidence-based causal transfer learning statistical methodology system". At the theoretical and methodological level, the project team first established a causal selection graph theoretical framework and constructed an RCT causal transfer statistical inference model encompassing both "data-driven" and "hypothesis-driven" approaches, effectively resolving issues of external validity inference under effect modifier interference and data missingness. Simultaneously, the project team overcame the homogeneity assumption bottleneck of traditional MR by innovatively proposing a transfer learning-based Two-Sample MR method (TLMR) and a trans-ethnic federated genetic correlation bridging model (TEMR), and further developed a structural learning algorithm (MRSL) and a multi-mediation analysis method (PSE-MR) capable of reconstructing complex causal networks using only aggregated data. To support the validation and translation of these theoretical methods, the project leveraged the Shandong Health Medical Big Data Platform, deeply integrating multi-source heterogeneous data to construct eight high-quality longitudinal cohorts covering diseases such as chronic hepatitis B, aortic dissection, stroke, and gallstones. Based on this methodological system and database, the project team conducted extensive empirical studies, not only revealing the causal association between green coverage and cancer incidence at the macro-environmental level, but also confirming the survival benefits of opportunistic lung cancer screening and the pathogenic risk of visceral fat to pulmonary diseases at the clinical diagnosis and treatment level. This project has successfully accomplished its predetermined research objectives, with a total of 28 academic papers published (including 13 indexed in SCI), 3 invention patents and 4 software copyrights applied for, and the cultivation of 2 postdoctoral fellows, 7 doctoral candidates, and 15 master's students. The research outcomes have provided critical methodological tools for addressing the challenges of



causal inference in multi-source heterogeneous big data, successfully establishing a technical pathway for translating evidence-based medicine (EBM) findings into real-world applications.
关键词（用分号分开）： 因果推断； 迁移学习； 孟德尔随机化； 循证医学； 生物统计
Keywords (separated by;)： Causal Inference; Transfer Learning; Mendelian Randomization; Evidence-based Medicine; Biostatistics

NSFC-REPORT-2025



正文

《结题/成果报告》正文分为两个部分：**结题部分和成果部分**。请按照《结题/成果报告》填报说明及撰写要求填写。

（一）结题部分

1. 研究计划执行情况概述。

本项目预期目标是构建“大数据背景下循证因果迁移学习的统计方法体系”及其 R 软件包。预期目标的实现，旨在解决从随机对照试验（Randomized controlled trials, RCT）样本到目标人群、以及在异质性人群中进行 Two-Sample MR 时的因果证据外部有效性和泛化外推力问题。预期成果将丰富和发展因果推断理论方法，为循证医学实践提供关键的方法学工具。项目预期发表 SCI 论文 8~15 篇；登记软件著作权 3~5 个、发明专利 2~3 项；培养博士后、博士及硕士研究生若干名。目前，本项目已圆满完成乃至超额完成既定任务。在理论方法上，成功构建了涵盖“数据驱动”与“假设驱动”的因果迁移统计推断模型体系，并创新性地提出了基于迁移学习的孟德尔随机化方法、跨种族/异质人群的迁移孟德尔随机化方法、基于贝叶斯网络的筛查迁移模型、加权生存贝叶斯网络以及多种基于偏倚函数的因果迁移模型。在成果产出方面，已在《*The American Journal of Human Genetics*》、《*JAMA Network Open*》、《*npj Digital Medicine*》、《*Briefings in Bioinformatics*》等国际权威期刊发表多篇高水平 SCI 论文；申请



了软件著作权 4 个；编制了相应的数据驱动因果迁移算法 R 软件包；培养了一批具备交叉学科背景的研究生人才。

（1）按计划执行情况。

1) 理论方法进展一：RCT 向观察性研究中因果效应迁移统计推断方法

针对试验样本到目标人群的因果推断泛化问题，本项目按计划完成了从单一 RCT 到多中心研究、从平均因果效应到个性化因果效应的迁移模型构建。在因果选择机制及选择图理论方面，针对标书中提出的嵌套和非嵌套两种 RCT 设计模式，我们系统推导了协变量 Z 在作为混杂变量、中介变量等不同角色下的选择机制及选择图。在此基础上，明确了实现试验样本到目标人群因果可识别性所需的关键假设条件，包括一致性、处理可交换性、正则性及选择可交换性，为后续统计模型的构建奠定了坚实的理论基础。

在数据驱动的因果迁移统计推断模型方面，本项目完成了以下三项核心工作：针对试验样本与目标人群样本均具备完整数据的情形，构建了数据驱动的平均因果效应（Average Causal Effect, ACE）迁移模型，重点解决了目标人群与试验人群异质性导致的效应修饰问题，推导了在存在效应修饰且无未观测混杂前提下的迁移估计公式，并开发了 do 算子的回归估计统计推断方法；针对多中心 RCT 场景，基于 Meta-Transportability 策略，构建了将多个试验样本数据融合并迁移至目标人群的统计推断模型。该模型能够有效整合来自不同中心的



因果证据，提升了因果效应估计的精度和泛化能力。该成果已完成文章一篇投稿于《*Nature Communications*》中。

在假设驱动的因果迁移统计推断模型方面，针对目标人群数据缺失的复杂情形（如仅有协变量 Z 数据），本项目构建了基于偏倚函数的因果迁移模型，涵盖了三种不同数据缺失与效应修饰组合的情形，通过引入偏倚参数并进行敏感性分析，实现了在非理想数据条件下对 RCT 外部有效性的稳健预估。同时，我们开展了广泛的统计模拟研究，验证了上述在不同选择机制及数据分布下的准确性、精确性与稳健性。目前，该成果已完成文章一篇投稿于《*Advanced Science*》中。

2) 理论方法进展二：异质总体两样本孟德尔随机化迁移学习方法

针对生物学大数据应用中，暴露样本与结局样本往往来自具有显著特征差异的异质性人群（如年龄结构、地域分布、基础疾病谱等差异），传统的 Two-Sample MR 方法因违反同质性假设而面临严峻的偏倚挑战。为此，本研究创新性地提出了一种基于迁移学习的 Two-Sample MR 方法（Transfer Learning based Two-sample Mendelian Randomization, TLMR）。该方法将暴露样本定义为源域，结局样本定义为目标域。针对协变量作为效应修饰因子导致的两人群因果效应不一致这一关键难题，TLMR 构建了一个两阶段的迁移估计框架：

首先在工具变量（Instrumental variables, IVs）-暴露关联阶段，识别并调整由于人群异质性导致的关联强度差异；其次在暴露-结局关联阶段，利用迁移学习算法对效应修饰因子的分布偏移进行加权校正。

通过这种机制，TLMR 成功放宽了传统 MR 对“同质性”的严格假



设，实现了因果证据从源域到目标域的无偏迁移。

为了验证 TLMR 方法的统计学性能，研究与目前主流的 8 种 MR 方法（包括 IVW、MR-Egger、Weighted Median、Weighted Mode、MR-RAPS、MR-PRESSO 等）进行了全面的模拟比较研究。结果表明，在存在显著群体异质性和效应修饰的复杂场景下，TLMR 方法表现出了最低的均方根误差和最小的估计偏倚，且保持了良好的置信区间覆盖率，显著优于传统方法。

此外，研究将 TLMR 方法应用于 UK Biobank 的大规模真实世界数据中，进行了一项极具代表性的实证研究。我们利用地理分割将人群划分为“英国北部人群”（作为源域）和“英国南部人群”（作为目标域），以模拟真实存在的地域和环境异质性，探究体重指数（Body mass index, BMI）对肺功能指标（包括第一秒用力呼气量 FEV1、用力肺活量 FVC 及 FEV1/FVC 比值）的因果效应。研究结果显示，在传统 MR 方法未能发现显著关联或结果不稳定的情况下，TLMR 方法成功检测到了 BMI 对肺功能的显著因果影响，揭示了肥胖对呼吸系统健康的潜在危害。这一实证结果不仅验证了 TLMR 在处理异质性数据时的稳健性和高灵敏度，也为跨地域、跨人群的因果推断提供了一种强有力的分析工具。目前，该成果已投稿至顶级期刊《*Briefings in Bioinformatics*》并结束二轮审稿。

3) 理论方法进展三：真实世界因果效应迁移统计推断方法体系扩展（超额完成）

为进一步达成真实世界因果效应的迁移工作，本项目针对真实世



界数据的迁移方法展开了拓展，超额完成了任务。

① 多中心筛查模型迁移学习方法：基于贝叶斯网络的可解释性模型（BOUND）

针对电子健康记录（Electronic health record, EHR）中普遍存在的数据缺失及异质性问题，我们开发了名为 BOUND（Bayesian network for large-scale lung cancer Digital prescreening）的可解释性贝叶斯网络模型。该模型利用 Cheeloo LEAD 数据库（涵盖山东省数百万人的 EHR 数据）构建，创新性地提出了“BN-logistic”参数学习方法，有效解决了稀疏数据下的参数估计难题。BOUND 模型利用贝叶斯网络的不确定性推理能力，实现了在数据缺失情况下的肺癌风险精准预测。在包含 905,194 人的大规模验证中，模型表现优异：内部验证 AUC 达到 0.866；在跨时间和跨地域的外部验证中，AUC 分别达到 0.848 和 0.841，验证了其强大的泛化能力。即使在数据缺失率高达 10%~70% 的情形下，模型 AUC 仍保持在 0.827~0.746 之间，显示了极高的稳健性。此外，基于该模型开发的风险评分卡将肺癌检出率提高了 6.8 倍，提供了一种非辐射、低成本且高效的肺癌数字预筛查方案，相关成果已发表于数字医疗顶级期刊《npj Digital Medicine》。

② 基于 Meta 迁移策略的加权生存贝叶斯网络方法研究（WSBN）

针对真实世界 EHR 数据中普遍并存的右删失与数据缺失双重挑战，传统的生存分析方法（如 Cox 比例风险模型）往往面临严峻考验。它们通常要求协变量完整，直接剔除缺失样本会导致统计效能降低及选择偏倚，而常规插补方法又可能引入额外噪声。为此，本项目



创新性地提出并构建了加权生存贝叶斯网络（Weighted Survival Bayesian Network, WSBN）因果预测模型。该模型在方法学上的核心突破在于巧妙融合了逆概率删失加权（Inverse Probability of Censoring Weighting, IPCW）技术与贝叶斯网络（Bayesian Network, BN）的推理优势。首先利用 IPCW 方法估计每个个体的删失概率，并据此赋予相应的权重，有效校正了因随访丢失或研究结束造成的删失偏倚，重构了目标人群的生存分布。随后，利用贝叶斯网络强大的概率依赖结构学习能力，在加权后的数据集上建立变量间的因果网络。这种设计使得模型无需进行显式的缺失值插补，即可通过贝叶斯推断直接利用非完整数据进行风险预测，最大化了真实世界数据的利用率，并保证了因果解释的直观性。

为了验证 WSBN 模型的实证效能，团队开展了一项基于大规模真实世界数据的回顾性队列研究。数据来源于威海市立医院的 EHR 系统，涵盖了 2013 年至 2021 年间共 169,692 名参与者（年龄 18-96 岁），其中确诊冠心病事件患者 10,895 例。研究纳入了包括人口统计学特征、体格检查指标、实验室生化指标及既往病史在内的多维风险因子。研究将数据分为训练集（ $n=110,325$ ，完整样本）和验证集（ $n=59,367$ ，包含缺失数据），全面评估模型在处理复杂 EHR 数据时的表现。通过与经典的 Cox 比例风险模型及其他机器学习方法进行比较，研究结果显示，WSBN 模型在各项评估指标上均优于传统模型。在关键的辨别度指标上，WSBN 模型在验证队列中的受试者工作特征曲线下面积（Area under the receiver operating characteristic



curve, AUC)高达 0.837(95% CI: 0.821–0.853), 一致性指数达到 0.838 (95% CI: 0.822–0.854), 显著高于 Cox 模型在相同数据集下的表现。在校准度方面, 校准曲线显示 WSBN 的预测概率与实际观察到的 CHD 发生率高度吻合, 表明模型并未出现明显的过拟合或欠拟合。此外, 决策曲线分析进一步证实, 在广泛的阈值概率范围内, 应用 WSBN 模型进行风险分层能带来显著的临床净获益。相关成果已发表于《*Journal of the American Heart Association*》。

③ 融合迁移学习的多任务生存分析方法

针对临床实践中日益普遍的“多病共存”现象, 传统的慢性病风险预测模型往往针对单一疾病独立建模, 忽略了不同慢性病之间在病理生理学上的内在联系和共享风险因素。这种独立建模方式在面对某些发病率较低或样本量相对不足的疾病时, 常因无法利用相关疾病的信息而导致预测精度受限。为此, 本研究创新性地构建了融合迁移学习的多任务生存分析模型 (Multi-task Learning Cox Model, MTL-Cox)。

MTL-Cox 模型在一个统一的计算框架下, 同时对多种慢性疾病的生存数据进行建模。该模型的核心在于引入了迁移学习机制, 通过在损失函数中加入组稀疏正则化项, 强制不同疾病的预测模型共享一部分特征权重或隐藏层参数。这种“借用强度”的机制使得模型能够从数据丰富、相关性强的“源任务” (常见病) 中提取共享的知识 (如共有的风险因子模式), 并将其有效地迁移到“目标任务” (少见病或数据稀疏疾病) 中。这不仅减少了模型的过拟合风险, 还显著提升了对特定疾病的泛化预测能力。



研究将 MTL-Cox 模型应用于 UK Biobank 的大规模队列数据中，针对 9 种严重影响人群健康的慢性疾病（包括冠心病、2 型糖尿病、卒中、慢性阻塞性肺病、肺癌、乳腺癌等）进行了全方位的实证研究。研究结果显示，与传统的单任务 Cox 比例风险模型及随机生存森林相比，MTL-Cox 模型在所有 9 种疾病的风险预测中均表现出更优或相当的性能。特别是在样本量相对较小的疾病任务中，得益于迁移学习带来的信息增益，MTL-Cox 模型的预测一致性指数相比传统模型最高提升了 12%。同时，该模型不仅能准确预测单一疾病的发生风险，还能计算个体在未来特定时间窗口内患多种疾病的绝对风险，并据此生成个性化的疾病风险排序列表。这为临床医生识别个体的高危疾病、制定精准的综合防控策略提供了强有力的量化工具。相关研究成果已发表于计算生物学权威期刊《*PLOS Computational Biology*》。

4) 理论方法进展四：异质总体孟德尔随机化迁移学习方法体系扩展（超额完成）

为了更妥善地应对多中心 GWAS 数据的迁移，本项目对异质总体孟德尔随机化迁移学习方法加以拓展，超额完成了任务。

① 跨种族异质数据库背景下的因果效应迁移学习方法（TEMR）

为解决小样本量的 GWAS 汇总数据不足以提供稳健的因果证据的问题，本项目构建了多中心生物标记迁移融合的联邦遗传相关桥接 MR 模型，利用不同种族间的遗传相关性，提高 MR 在估计代表性不足人群中因果效应的准确性和统计效能，为疾病的发展机制、预防措施、诊断和治疗提供新的见解。模拟结果表明，无论辅助人群和



目标人群中的因果效应是否一致，本项目提出的方法（Trans-ethnic Mendelian Randomization, TEMR）对因果效应的估计都是无偏的，且相对于其他七种方法显示出更高的精度和统计效能。随着跨种族遗传相关性的增加，TEMR 的精度也逐渐提高，与其他七种方法相比 TEMR 的统计效能也显著提高。此外，TEMR 表现出稳定的 I 类错误率，不受跨种族遗传相关性或辅助人群中的因果效应变化的影响。在实例应用部分，本项目使用 TEMR 推断了 16 种生物标志物与 5 种慢性疾病（高血压、缺血性中风、2 型糖尿病、精神分裂症和抑郁症）之间的因果关系。结果表明，与其它七种方法相比，TEMR 识别出了更多与各种结果显著相关的生物标志物。相关成果发表于《*The American Journal of Human Genetics*》杂志。

② 基于选择图的两样本孟德尔随机化估计不一致性解构方法

针对 Two-Sample MR 研究中经常出现的“不一致因果估计”（Inconsistent Two-Sample MR Estimations, InTSMRE）难题，即不同的有效 IVs 往往得出相互矛盾的因果估计结果，本研究利用选择图理论深入揭示了其发生机制。此类不一致性通常源于两样本人群的异质性，但传统方法缺乏系统的诊断工具。为此，本研究旨在构建一套理论框架与分析流程，帮助研究者识别不一致的来源并选择合适的估计策略。

本研究利用因果图理论，构建了包含选择节点的因果结构图，创新性地将 InTSMRE 系统划分为“完全不一致”和“部分不一致”。理论推导证明，完全不一致源于两样本间在暴露、结局或未观测混杂



的局部生成机制上存在系统性差异；而部分不一致则特指仅由结局的局部机制差异引起。这一理论分类明确了不一致性的具体来源（例如是生物学机制改变还是混杂结构差异），为后续的偏差校正提供了坚实的理论依据。

基于上述理论，研究提出了一套实用的四步诊断与分析流程：数据准备；局部平均处理效应估计；InTSMRE 分类与 IVs 筛选；不一致性来源的诊断分析。该流程能够帮助研究者通过统计检验（如单调性假设检验）识别导致估计不一致的具体异质性来源，从而指导其剔除不适用的 IVs 或选择合适的估计策略，在保证因果推断可靠性的同时最大化数据利用率。研究进一步将该理论应用于分析“腰臀比对 2 型糖尿病”的因果效应。实证结果展示了如何利用该指南区分不同 IVs 的适用性，识别出违反假设的 IVs，从而获得更稳健的推断结果。相关成果发表于《*BMC Medical Research Methodology*》。

5) 理论方法进展五：复杂因果网络与机制学习方法体系（超额完成）

为了通过构建可迁移、可解释的因果学习框架，解决传统方法在跨领域、跨数据形态下因果识别稳定性与泛化能力不足的挑战，本项目还系统提出了基于遗传汇总数据的因果结构学习、因果多中介分析以及 AI 智能体驱动的因果网络学习与验证等方法，不仅提升了因果推理的准确性与可解释性，也为迁移学习在医学、生物等复杂场景下的稳健应用提供了理论工具与实证基础。

① 基于遗传汇总数据的因果结构学习算法（MRSL）

针对复杂疾病多表型间的因果网络推断难题，传统因果发现算法



（如 PC、GES 等）往往依赖个体水平数据，且在存在未观测混杂时难以识别准确的因果结构。鉴于全基因组关联研究（Genome-wide association study, GWAS）汇总数据的广泛可获取性，本项目创新性地提出了一种基于遗传汇总数据的因果结构学习算法（MR-based Structure Learning, MRSL）。其核心思想是将因果结构学习问题转化为网络剪枝问题，利用 MR 方法估计变量间的成对边缘因果效应，首先构建一个包含所有潜在关联的初始全连接网络。随后，基于线性结构方程模型的理论性质，推导出了在存在潜在混杂因素情形下的因果结构可识别性条件。MRSL 通过一种迭代的剪枝策略，系统地检验并剔除那些可以被其他中间变量完全解释的“冗余边”（即间接效应路径），从而逐步还原出变量间真实的直接因果网络。该方法的一大理论突破在于放松了经典的“因果充分性”假设，即允许系统中存在未被观测的共同原因，这使得该算法在复杂的生物医学真实场景中具有更广泛的适用性。

为了评估 MRSL 算法的性能，研究在多种网络规模、不同样本量及不同程度混杂干扰的设置下进行了广泛的统计模拟研究。结果表明，与现有的主流因果发现算法（包括 PC-Stable、GES、MVPC 等）相比，MRSL 在识别因果骨架和定向方面均表现出更高的准确性。特别是在以 F1-score 作为综合评价指标时，MRSL 始终保持领先，且表现出极佳的稳健性，有效克服了传统方法在处理汇总数据和潜在混杂时的局限性。

研究进一步将 MRSL 算法应用于 20 种复杂性状（涵盖脂质代



谢指标、人体测量学指标、血糖代谢指标等)的 GWAS 汇总数据分析中。研究成功重构了一个包含多层次因果关系的复杂性状网络,不仅验证了已知的生物学通路(如 BMI 对甘油三酯的直接正向因果效应),还揭示了一些新的潜在因果机制(如某些脂质成分间的定向调控关系)。该实证研究证明了 MRSL 作为一种强大的数据挖掘工具,能够从海量遗传汇总数据中高效提取因果知识,为解析复杂疾病的致病机理提供了全新的视角。相关成果已发表于生物信息学领域权威期刊《*Briefings in Bioinformatics*》。

② 基于遗传汇总数据的因果多中介方法(PSE-MR)

针对复杂疾病发生发展机制中普遍存在的多路径、多中介现象,特别是当介导变量之间存在因果时序或无序关系时,传统的因果中介分析方法难以利用海量遗传汇总数据进行有效推断。为此,本研究创新性地提出了基于遗传汇总数据的路径特异性效应孟德尔随机化方法(Path-Specific Effect Mendelian Randomization, PSE-MR)。

PSE-MR 方法的核心突破在于能够仅使用 GWAS 汇总统计量,识别并估计暴露因素通过特定中介路径对结局的因果效应(Path-Specific Effects, PSEs)。该方法放松了传统中介分析中严格的“时序可忽略性”假设,允许暴露、中介与结局之间存在未观测的混杂因素。通过构建结构方程模型并引入秩条件(Rank Condition, 即 IVs 数量大于中介变量数量),PSE-MR 能够有效地将总因果效应分解为直接效应和经由不同中介变量的间接效应,从而在复杂的因果网络中精准定位关键的致病通路。



广泛的统计模拟研究表明,PSE-MR 在多种参数设置下均能保持稳健的性能,估计偏差极小且置信区间覆盖率良好。将该方法应用于探究受教育程度对骨关节炎的影响机制,成功识别了 BMI 和吸烟在其中的特定中介作用;此外,在 BMI 到心血管疾病的路径分析中,PSE-MR 精准解析了不同血脂指标的特定介导效应。这些发现不仅阐明了疾病发生的具体生物学路径,也为制定针对性的干预策略提供了确凿的因果证据。相关成果已发表于医学统计学权威期刊《*Statistical Methods in Medical Research*》。

③ AI 智能体驱动的因果网络学习与真实世界验证

本项目坚持理论与应用相结合,创新性地引入 AI 智能体 (AI Agent) 学习方法作为实证研究的前置基础,确保了因果推断的科学性与准确性。针对标书中提出的复杂因果关系识别难题,我们首先应用新提出的 AI 智能体学习方法对海量医学文献和真实世界数据进行深度挖掘。该方法能够自动构建高精度的因果网络,从现有研究中智能识别并严格筛选出关键的风险因素和混杂因素。这一步骤有效剔除了伪关联变量,确立了稳健的因果结构先验,为后续的统计建模奠定了坚实基础。

6) 医院端队列数据库的构建

为了将本项目提出的理论方法更有效地应用于真实世界研究,本项目依托山东省多个医院和中心的健康医疗大数据,构建了多个医院端队列数据库。

依托国家健康医疗大数据北方中心构建的中心化与去中心化优



势互补联盟链支撑的医学科学大数据资源协作网，在济南、临沂、淄博、济宁、滨州和青岛等地构建了数据库，以山东省全民健康信息平台、临沂市人民医院和淄博中心医院三个中心作为主要合作中心，开展了多项队列课题研究。

依托山东省临沂市人民医院 2003 年 1 月 8 日至 2023 年 1 月 9 日、时间跨度 20 年、共计 41,500,492 人次、10,100,279 人，覆盖门诊、住院和健康体检的电子病历记录，构建多领域的健康管理纵向观察队列数据库。

依托山东省淄博中心医院 2004 年 1 月 5 日至 2023 年 6 月 21 日、时间跨度 19 年余、共计 1,722,624 人次、93,445 人，覆盖门诊、住院和健康体检的电子病历记录，构建心衰领域的纵向观察队列数据库。

依托山东省立第三医院肝胆外科的学科优势，收集 2010 年 1 月至 2025 年 2 月期间 16,762 名胆囊切开取石术或胆囊切除术手术患者的电子病历数据，并以患者身份证号码为唯一索引，关联山东省全民健康信息平台获取随访结局信息，构建齐鲁胆囊结石手术全生命周期结局数据库（Cheeloo GOLD）。队列时间跨度 15 余年，包含共计 120,654 条门诊记录和 25,541 条住院记录。

依托山东省立第三医院肝胆外科的学科优势，收集 2010 年 1 月至 2025 年 2 月期间 1932 名主动脉夹层患者的电子病历数据，并以患者身份证号码为唯一索引，关联山东省全民健康信息平台获取随访结局信息，构建齐鲁主动脉夹层患者全生命周期结局数据库。队列时间跨度 15 余年，包含共计 15,137 条门诊记录和 3,346 条住院记录。



7) 成果推广与应用

在上述经严格筛选的风险因素和混杂因素集的基础上，本项目在利用构建的迁移学习统计模型在癌症和重大慢性病领域进行了广泛的实证研究：

① 肿瘤防控领域的病因探索与筛查评价

针对癌症起源理论争议及筛查策略优化难题，本项目综合应用生态学模型、观察性因果推断及倾向性评分方法，从宏观环境到微观筛查进行了全方位研究。

环境因素因果效应分析：癌症的发生是遗传与环境因素共同作用的结果，探索环境相关的癌症预防措施具有必要性，绿色覆盖是其中的关键要素。本项目依托山东省健康医疗大数据平台，将平邑县居民电子健康档案、癌症监测数据和电子病历数据进行关联，构建癌症发病队列。以卫星遥感数据来源的归一化植被指数作为暴露指标，以癌症发病作为结局，首先采用广义线性混合模型探索绿色覆盖与癌症发病的关联关系，然后利用基于时间序列的阴性对照暴露方法进行因果关联分析。结果显示，绿色覆盖与癌症发病之间存在保护性因果关联，这为癌症的一级预防提供了环境流行病学参考。成果发表在《山东大学学报（医学版）》。

筛查效果的真实世界评价：肺癌人群筛查指南及随机对照临床试验的证据支持基于高危人群的肺癌 LDCT 筛查可有效降低肺癌死亡率，但人群筛查覆盖率及参与度有限。本项目应用国家健康医疗大数据研究院大数据平台构建区域性肺癌专病队列，根据患者是否通过机



会性筛查确诊为肺癌，采用倾向性评分匹配方法控制组间（筛查组、非筛查组）的混杂因素，应用 Cox 回归模型分析 LDCT 机会性筛查与肺癌预后之间的关联。研究发现 LDCT 机会性筛查与肺癌死亡风险降低 49% 相关，与全因死亡风险降低 46% 相关，证实肺癌机会性筛查可作为高危人群筛查的重要补充，改善肺癌患者的预后，相关成果发表于《JAMA Network Open》。

② 心脑血管及代谢性疾病的精准防诊治

利用本项目在贝叶斯网络及效应修饰分析方面的技术优势，构建了精准的疾病筛查与风险分层模型。

缺血性脑卒中贝叶斯筛查模型：本项目依托大规模 EHR，结合贝叶斯网络不确定性推理的优势，构建缺血性脑卒中筛查模型。筛查模型开发队列来自于齐鲁全生命周期电子研究型数据库，按照 7:3 比例分为训练集与测试集，外部验证队列来自国家健康医疗大数据研究院博兴合作中心数据库，采用单因素 Logistic 回归分析筛选与缺血性脑卒中发病显著相关的筛查因子，随后采用贝叶斯网络模型对筛查因子建模，利用禁忌搜索算法进行结构学习，利用贝叶斯估计算法进行参数学习，最终得到缺血性脑卒中筛查模型。训练集、测试集和外部验证队列的 AUC 分别为 0.840、0.839 和 0.811，模型的判别能力良好，并且校准能力仍旧表现较好。成果发表在《山东大学学报（医学版）》。

效应修饰与精准预防策略：在心血管疾病防控领域，本项目基于 UK Biobank 队列深入研究了心血管-肾脏-代谢（CKM）综合征对吸



烟致病风险的效应修饰作用。研究发现 CKM 分期显著修饰了吸烟与 CVD 及其亚型（如冠心病、卒中）的关联强度，揭示了在不同 CKM 病理阶段下戒烟带来的差异化心血管获益，为制定个性化的精准预防策略提供了坚实的实证依据，成果发表在《*BMC Public Health*》。

③ 复杂疾病因果机制的孟德尔随机化解析

应用本项目发展的多变量 MR、网络 MR 及双向 MR 方法，系统解析了生活方式、遗传因素与复杂疾病之间的因果通路。

生活方式与功能性疾病：肠易激综合征（IBS）是一种慢性功能性胃肠道疾病。既往研究发现，IBS 的发生发展与睡眠性状、精神状态及心理因素相关，但其视角局限于传统观察性流行病学，易受未知混杂和反向因果的影响。本项目利用大规模全基因组关联研究汇总数据和芬兰生物银行数据，选择相互独立且与睡眠性状密切相关的遗传位点作为 IVs，通过逆方差加权法、加权中位数法、简单中位数法、稳健的调整轮廓评分法、MR 多效性残差和与异质性法等 MR 方法，以 OR 值作为评价指标对睡眠性状与 IBS 的因果关系进行探讨。结果显示，过短睡眠和失眠会增加 IBS 的发病风险，早起型失眠习惯可能会降低 IBS 的发病风险，提示良好的睡眠习惯对 IBS 的预防和治疗具有积极效果。因此，在 IBS 健康管理全过程中应改善失眠症状、提高睡眠质量。成果发表在《*山东大学学报（医学版）*》。

全生命周期网络因果推断：过往研究表明，妊娠期对眼病有显著影响；同时已经有大量证据表明，细胞因子与妊娠期和眼病有关。然而细胞因子、母体妊娠障碍和后代眼病之间的因果关系尚不清楚。本



项目使用来自大型全基因组关联研究的汇总级数据进行生命过程网络 MR，以探索母体妊娠期、新生儿/成人细胞因子与成人眼部疾病之间的因果关系。分析流程采用了网络 MR 设计，首先使用单变量 MR 方法来计算孕龄对眼部疾病的总效应，然后使用生命历程 MR 方法来计算妊娠时长对细胞因子水平的因果效应以及细胞因子水平对眼部疾病的因果效应，最后应用多元 MR 方法，其目的是计算妊娠时长对眼部疾病的直接效应，而不是细胞因子的效应。分析结果显示，母亲的胎龄（早产、早产、胎龄长短和足月产）与 42 种眼病有因果关系。同时，在八种眼病中四种新生儿细胞因子与四种成人细胞因子是早期早产与早产之间因果关系的中介因子，在对这些中介因子进行调整后，发现早期早产和早产对八种眼病的直接因果效应为零。成果发表在《*International Immunopharmacology*》。

全生命周期网络因果推断：本项目基于大规模全基因组关联研究的汇总统计数据，采用 Two-Sample MR 和双向 MR 探索了 83 种饮食习惯与偏头痛及其亚型之间的潜在因果关系，并采用网络 MR 研究了 8 种偏头痛危险因素可能的中介作用。结果表明，基因预测的咖啡、奶酪、油性鱼、酒精、生蔬菜、什米粥和全麦面包摄入与偏头痛风险降低存在显著因果关联；而白面包、玉米片/霜冻和家禽摄入量增加会导致偏头痛的风险上升。此外，失眠和 MDD 介导了某些饮食习惯对偏头痛的因果效应。最后，本研究发现了偏头痛与饮酒存在负相关，而与每天喝茶呈正相关。成果发表在《*Frontiers in Nutrition*》。

自身免疫共病机制：系统性红斑狼疮（SLE）是一种影响许多器



官的自身免疫性疾病，1 型糖尿病（T1D）也是一种自身免疫性疾病。该疾病的原因是产生胰岛素的 β 细胞的器官特异性免疫破坏的结果。一旦确诊，需要终身胰岛素治疗，如果不及时治疗，可能会出现许多与 T1D 相关的并发症。尽管观察性研究的结果表明，T1D 和 SLE 相互作用，受到观察性研究本身存在的混杂因素的影响，但无法确定两者之间的因果关系。由于随机对照试验的设计费力、费时、费用昂贵，且 SLE 和 T1D 的发病率不高，开展大规模随机对照试验尤其困难。考虑到混杂因素调整不充分可能导致 T1D 与 SLE 之间相关性的偏差，需要更好的方法来评估因果关系的证据。本研究使用公开的欧洲全基因组关联研究汇总数据，选择独立并与暴露密切相关的单核苷酸多态性（Single nucleotide polymorphism, SNP）作为 IVs。使用逆方差加权法、MR-Egger，加权中位数方法，MR-Robust 等方法进行分析。结果显示 T1D 与 SLE 呈双向因果关系。需要进一步的研究来阐明 T1D 与 SLE 之间潜在的生物学机制。成果发表在《*Clinical Rheumatology*》。

内脏脂肪与肺部疾病因果关联解析：肺部疾病已成为全球严重的公共卫生负担，环境与遗传因素交织。既往流行病学研究虽提示肥胖与多种肺部疾病相关，但传统指标难以区分脂肪分布，且观察性研究易受混杂因素及反向因果干扰，导致具体致病成分不明。本项目利用目前最大的内脏脂肪组织全基因组关联研究汇总数据及 FinnGen 和 TRICL 联盟的肺部疾病数据，选择相互独立且与 VAT 强相关的 SNPs 作为 IVs，采用 IVW、MR-Egger 回归、WME、MR-PRESSO



及 MR-RAPS 等多种 MR 方法，系统评估 VAT 对 7 种常见肺部疾病的因果影响。结果显示，遗传预测的较高 VAT 显著增加了睡眠呼吸暂停、慢性阻塞性肺病、肺癌及肺炎的发病风险，并存在增加肺栓塞风险的提示性证据，而与特发性肺纤维化及肺结核无显著因果关联。研究确证了内脏脂肪积累是多种肺部疾病的独立因果风险因素，提示内脏减脂在肺部疾病预防中的重要价值。成果发表在《山东大学学报（医学版）》。

（2）研究目标完成情况。

对照项目计划书设定的研究内容与考核指标，本项目紧密围绕“RCT 及观察性研究因果效应迁移”和“异质总体两样本孟德尔随机化迁移”两大核心任务开展研究。项目不仅圆满完成了标书规定的各项理论推导与模型构建任务，还在复杂因果网络学习与真实世界实证应用方面进行了深度拓展，形成了体系完备的研究成果。

1) 针对“试验样本到目标人群的因果推断泛化”任务，构建了 RCT 及观察性研究因果迁移统计推断方法体系。针对试验样本与目标人群样本数据完备情况不同的情形，基于选择图理论，系统推导了迁移模型；同时为了应对真实世界数据的复杂性，进一步拓展了该模型体系适用边界：针对多病共存场景下的稀疏数据预测难题，开发了融合迁移学习的多任务生存分析模型（MTL-Cox），通过“借用强度”机制，实现了从常见病向罕见病的知识迁移，显著提升了慢性病个性化预测的精度；针对真实世界 EHR 数据中广泛存在的删失与缺失并



存问题，基于 Meta-Transportability 策略构建了加权生存贝叶斯网络（WSBN）。创新性地融合了 IPCW 加权与贝叶斯网络推理，实现了在无需插补条件下的稳健因果预测；同时开发了多中心筛查迁移模型（BOUND），成功实现了大规模肺癌数字筛查模型在跨地域、跨时间人群中的泛化应用，解决了医疗 AI 模型“水土不服”的难题。

2) 针对“异质总体因果关联效应推断”任务，构建了异质性孟德尔随机化迁移学习方法体系。针对协变量作为效应修饰因子导致的同质性假设失效，创新性提出了基于迁移学习的孟德尔随机化方法（TLMR），将 MR 重构为从源域到目标域的迁移学习问题，通过两阶段加权校正有效纠正了异质性偏差；针对跨种族因果推断中小样本数据效能不足的问题，构建了联邦遗传相关桥接 MR 模型（TEMR）。利用不同种族间共享的遗传相关性结构作为桥梁，实现了多中心生物标记的无偏迁移估计；针对 Two-Sample MR 中不同有效 IVs 往往得出不一致因果估计的理论难题，利用选择图理论提出了 InTSMRE 解构方法，明确了“完全不一致”与“部分不一致”的发生机制，并给出了实用的诊断与分析流程；同时系统探讨了 49 种非随机选择机制对 MR 估计的影响，揭示了结局依赖性选择及多效性存在时会显著放大 I 类错误率。这一发现为 Two-Sample MR 研究的样本纳入标准提供了重要的理论预警。

3) 为适应大数据背景下解析复杂疾病机制的需求，本项目在完成标书计划基础上进行了深度拓展，攻克了仅利用 GWAS 汇总数据构建高维因果网络的技术难题。针对复杂疾病多表型网络构建，提出



了基于 MR 剪枝策略的结构学习算法，放松了经典的“因果充分性”假设，允许未观测混杂的存在，成功在 20 种复杂性状中重构了多层级因果网络；针对多路径、多中介（有序/无序）的复杂机制，提出了 PSE-MR 方法，仅用汇总水平数据即可精准识别特定通路的因果效应，成功解析了骨关节炎及心血管疾病中的关键中介机制。

2. 研究工作主要进展、结果和影响。

（1）主要研究内容。

1) 基于 Pearl 因果图理论，针对 RCT 常见的嵌套与非嵌套设计，系统研究协变量在作为混杂变量、中介变量或碰撞变量等不同角色下的选择机制，并绘制了指导迁移的选择图。在此理论框架下，确立了处理一致性、条件可交换性、正值性及选择可交换性等因果效应可识别性的核心假设。

2) 针对“试验样本具备完整数据，而目标人群仅有协变量数据”或“仅有部分汇总数据”等极端情形，本研究不再依赖数据的完全可识别性假设，而是建立假设驱动的因果迁移推断框架。通过引入偏倚函数来刻画试验人群与目标人群之间未被观测的选择机制差异，构建基于灵敏度参数的因果迁移模型。

3) 针对传统 Two-Sample MR 研究中暴露样本与结局样本来自异质性群体（如种族、地域、环境背景差异）从而违反同质性假设这一关键难题，创新性地将迁移学习思想引入 MR 领域，构建适应异质总体的因果关联迁移模型，重点解决协变量作为效应修饰因子导致



的分布偏移问题，实现因果效应在异质人群间的稳健迁移与推断。

4) 为适应大数据时代从单纯因果估计向复杂病因网络解析的深入，本研究在原计划基础上进行了深度拓展，攻克仅利用 GWAS 汇总统计量构建高维因果网络的技术瓶颈，提出了新的因果结构学习算法，放松经典的“因果充分性”假设，允许未观测混杂的存在，实现了从海量汇总数据中重构多层级因果网络。同时，针对多路径、多中介（有序或无序）的复杂机制构建路径特异性效应分析方法。

（2）取得的主要研究进展、重要结果、关键数据等及其科学意义或应用前景。

1) 理论方法进展一：RCT 向观察性研究中因果效应迁移统计推断方法

背景：RCT 在反事实模型框架下，通过“事前随机化”有效切断混杂路径，确立了其作为因果推断“金标准”的地位。然而，RCT 为追求理想的内部有效性，往往采用严格的纳入排除标准，导致试验样本对目标人群的代表性较差，这种不可避免的选择偏倚严重制约了因果证据的外部有效性与泛化外推力。当前，随着电子病历、EHR 及高通量组学等大数据的广泛普及，获取海量协变量信息成为可能。充分利用这些丰富信息，研究从 RCT 试验样本到异质性目标人群或真实世界的“因果证据迁移”，已成为打破循证医学瓶颈、实现内部与外部有效性评价无缝对接的关键领域。与此同时，基于大型观察性研究的 Two-Sample MR 设计，也成为获取广泛因果关联证据的有效



普及性策略。

方法：针对试验样本与目标人群样本具备处理 (X)、结局 (Y) 和协变量 (Z) 数据的不同情形，分别构建迁移模型。

A. 数据驱动下 X 到 Y 因果效应迁移的统计推断模型研究

试验样本 ($S=1$) 与目标人群 ($S=0$) 均具备完整的处理 X 、结局 Y 和协变量 Z 数据。利用合并数据学习选择图结构，并进行无偏迁移，识别目标人群的干预分布 ($(X=1, Z=0)$)。

在给定协变量 Z 后，结局 Y 的生成机制在两群间保持一致，即

(X, Z) 时，可得

$$\begin{aligned} P(Y=1 | X=1, Z=0) &= P(Y=1 | X=1, Z=0, S=0) P(Z=0) \\ &= P(Y=1 | X=1, Z=0, S=1) P(Z=0) \\ &= P(Y=1 | X=1, Z=1, S=1) P(Z=0) \end{aligned}$$

线性模型推导

在 $S=1$ 中拟合 $[Y | X, Z, S=1] = \beta_0 + \beta_X X + \beta_Z Z + \beta_{XZ} XZ$ 。

其中 β_X 代表 X 的主效应， $\beta_Z Z$ 是协变量的主效应， $\beta_{XZ} XZ$ 是 X 与 Z 的交互效应。

线性模型迁移成立当且仅当：模型正确设定；S-admissibility 成立，即 Z 包含了所有效应修饰因子，使得 (X, Z) 。

在协变量 Z 层面，因果效应为干预 $X=1$ 与 $X=0$ 的期望之差：



$$\begin{aligned} \tau_1(Z) &= [E(Y=1, S=1) - E(Y=0, S=1)] \\ &= (E_0 + \beta_1 + \beta_2) - (E_0 + \beta_2 + 0) \\ &= \beta_1 \end{aligned}$$

目标人群的 ACE 是 $\tau_1(Z)$ 在目标人群分布 $P(Z|S=0)$ 下的期望：

$$\begin{aligned} E_{S=0}[\tau_1(Z)] &= E_{S=0}[\beta_1] \\ &= \beta_1 \\ &= \beta_1 \end{aligned}$$

最终计算公式：

$$ACE = \beta_1 + \beta_2 \cdot Z^{(0)}$$

其中 $\beta_{x,\eta}$ 来自试验样本回归， $Z^{(0)}$ 为目标人群协变量均值。

Logistic 模型推导

当结局为二分类变量时：

$$P(Y=1 | X, S=1) = \frac{e^{\beta_0 + \beta_1 X + \beta_2 S}}{1 + e^{\beta_0 + \beta_1 X + \beta_2 S}}.$$

由于 Logit 函数是非线性的， $P(Y=1 | X, S=1) \neq P(Y=1 | X, S=0)$ ，不能像线性模型那样直接用系数相加，必须先转换回概率尺度。研究通常关注的是风险差 (Risk Difference, RD)： $P(Y=1 | X, S=1) - P(Y=1 | X, S=0)$ 。对于目标人群中的每一个体 i (具有特征 Z_i)，利用试验模型参数预测其反事实概率，如下所示。

当干预 $X=1$ ，其风险为：

$$P_1 = \frac{1}{1 + e^{-(\beta_0 + \beta_1 + \beta_2)}}$$

当干预 $X=0$ ，其风险为：

$$P_0 = \frac{1}{1 + e^{-(\beta_0 + \beta_2)}}$$

最终通过对目标人群所有个体求平均，得：



$$= \frac{1}{0_{=0}} (1 - 0)$$

$$= \frac{1}{0_{=0}} \left(\frac{1}{1 + \frac{- (0^+ + + +)}{}} - \frac{1}{1 + \frac{- (0^+)}{}} \right)$$

Cox 比例风险模型推导

当结局 为生存时间 T (伴随删失) 时, 在试验样本 ($S=1$) 中拟合 Cox 模型:

$$h(\cdot, \cdot, = 1) = o(\cdot) \exp(\cdot + \cdot + (\cdot))$$

其中, $o(\cdot)$ 为基准风险函数, $\exp(\cdot + \cdot + (\cdot))$ 为风险比部分, 包含交互项以捕捉效应修饰。

研究者通常关注目标人群在特定时间点 的生存概率差或限制性平均生存时间差, 因此本研究使用 Breslow 估计量获得累积基准风险 $o(\cdot)$ 。则生存函数表达式为:

$$(\cdot) = \exp[-o(\cdot) \exp(\cdot + \cdot + (\cdot))]$$

对于目标人群中的每一个体 i (具有特征):

若干预 $= 1$, 则

$$(\cdot (1)) = \exp(-o(\cdot) \exp(\cdot + \cdot + (\cdot)))$$

若干预 $= 0$, 则

$$(\cdot (0)) = \exp(-o(\cdot) \exp(\cdot))$$

最终通过对目标人群求平均, 得:

$$(\cdot) = \frac{1}{0_{=0}} [(\cdot (1)) - (\cdot (0))]$$

② 假设驱动下 X 到 Y 因果效应迁移的统计推断模型研究

针对目标人群数据不完整 (如缺失结局或部分协变量) 或存在未



观测混杂的情形，采用“假设驱动”策略，构建基于偏倚函数（**Bias Function**）的敏感性分析模型。

针对试验样本具备 X, Y, Z 数据，而目标人群仅有 Z 数据情形

在此情形下，Do 算子识别所需的 $(\text{Do}(Z=0)) = (\text{Do}(Z=1))$ 无法直接验证。研究通过引入敏感性参数来放宽这一假设。

情形一：目标人群具备完整 $Z=(Z_1, Z_2)$ ，且 Z 分布不同

在情形一下，本研究考虑两个场景：（1） Z_1 （同质），（2） Z_2 /（异质）。

则对 Z_2 ，此时结构不变性假设可能失效，即 $(\text{Do}(Z_2=0)) \neq (\text{Do}(Z_2=1))$ 。

Do 算子视角下的偏倚定义

定义“条件因果效应的漂移”为偏倚函数 (Bias) ：

$$[\text{Do}(Z_2=0)] - [\text{Do}(Z_2=1)] = (\text{Bias})$$

通常假设漂移是 x 的线性修饰： $(\text{Bias}) = (\Delta \cdot Z_2)$ ，其中 Δ 为敏感性参数。

线性模型推导

定义试验样本的条件因果效应为 $\tau_1(x) = \tau_0(x) + \tau_1 \cdot Z_1 + \tau_2 \cdot Z_2$ 。

假设目标人群的真实效应 $\tau_0(x)$ 与试验效应存在偏差，且该偏差是异质变量 Z_2 的函数：

$$\tau_0(x) = \tau_1(x) + (\text{Bias}; \Delta)$$

$$(\text{Bias}; \Delta) = \Delta \cdot Z_2$$



其中 Δ 为假设的系数漂移量。通过计算 $\pi_0(\cdot)$ 在目标人群分布下的期望，可得目标 ACE 为：

$$\begin{aligned}\pi_0(\Delta) &= \pi_0[\pi_1(\cdot) + \Delta \pi_2] \\ &= \pi_0[\pi_1 + \pi_1 \pi_1 + \pi_2 \pi_2 + \Delta \pi_2] \\ &= \pi_1 + \pi_1 [\pi_1 = 0] + (\pi_2 + \Delta) [\pi_2 = 0]\end{aligned}$$

由此可得最终计算公式：

$$= (\pi_1 + \pi_1^{(0)} + \pi_2^{(0)}) + \Delta \pi_2^{(0)}$$

最终通过遍历 Δ 的取值范围（如 $\pm 10\%$ 的 π_2 ），可获得 ACE 的敏感性区间。

Logistic 模型推导

对二分类结局，假设偏倚发生在 Logit 线性预测层面：

$$(\pi = 1, \pi = 0) = (\pi = 1, \pi = 1) + \Delta \pi_2$$

其中 $\Delta \pi_2$ 代表只有在治疗 $\pi = 1$ 时，协变量 π_2 带来的额外效应差异。

针对目标人群个体 i ，通过如下流程可实现其线性预测值修正。

对试验模型预测值：

$$= \pi_0 + \pi_1 + \pi_2 + (\pi_2)$$

可得到修正后预测值：

$$= \pi_0 + \Delta \pi_2$$

进而有如下最终计算公式：

$$\begin{aligned}(\Delta) &= \frac{1}{\pi_0} (\pi_1^{-1}(\pi_1 + \Delta \pi_2) - \pi_1^{-1}(\pi_0)) \\ &= \frac{1}{\pi_0} \left(\frac{1}{1 + \pi_1^{-1}(\pi_0 + \pi_2 + \Delta \pi_2)} - \frac{1}{1 + \pi_1^{-1}(\pi_0)} \right)\end{aligned}$$



其中 β_0 为基于试验参数预测的 Logit 值。

Cox 比例风险模型推导

假设目标人群的对数风险比 (Log-HR) 与试验人群存在偏差,且该偏差是异质变量 Z_2 的函数:

$$\ln \lambda_{i0}(X_i) = \ln \lambda_{i1}(X_i) + \Delta_{i2}$$

这意味着 X 的效应系数发生了漂移: $\beta_0 \approx \beta_1 + \Delta_{i2}$ 。

在预测目标人群个体 i 的反事实生存率时,引入偏倚项 Δ_{i2} ,即可得如下最终计算公式:

$$S_{i0}(t, \Delta) = \exp(-\Lambda_0(t) \exp(\beta_0 + \Delta_{i2}))$$

$$S_{i1}(t, \Delta) = \frac{1}{S_{i0}(t, \Delta)} [S_{i0}(t, \Delta) - S_{i0}(t, 0)]$$

情形二: 目标人群缺失部分协变量 (仅有 Z_2 , 缺失 Z_1)

在这种情形下,无法直接观测 Z_1 在目标人群的分布 ($Z_1|Z_2=0$)。因此,对因果效应识别公式

$$E[Z_1|Z_2=1] - E[Z_1|Z_2=0]$$

其中 ($Z_1|Z_2=0$) 未知。对此,本研究通过引入分布漂移参数 δ ,构建如下模型:

$$[Z_1|Z_2=0] = [Z_1|Z_2=1] + \delta$$

在此模型下,通过外部知识确定 δ 的范围,进而对目标因果效应进行估计推断。具体而言,有如下确定策略。

外部数据借用: 参考同类人群的公共卫生统计数据或文献值。

专家咨询: 根据临床经验设定 Z_1 在两群间可能的差异范围。

敏感性扫描: 设定 $[-\sigma, +\sigma]$ (基于试验样本标准差) 进行



区间估计。

线性模型推导

进而，可得如下因果效应计算公式：

$$\begin{aligned} \tau_{=0}(\cdot) &= \beta_0 + \beta_1 [x_1 = 0] + \beta_2 [x_2 = 0] \\ &= \beta_0 + \beta_1 ([x_1 = 1] + 1) + \beta_2 [x_2 = 0] \end{aligned}$$

最终计算公式如下：

$$\tau(\cdot) = \underbrace{\left(\beta_0 + \beta_1 \frac{(1)}{1} + \beta_2 \frac{(0)}{2} \right)}_{\text{原始估计}} + \underbrace{\beta_1}_{\text{偏倚校正}}$$

Logistic 模型推导 (区间估计)

由于无法进行个体层面的均值填补（非线性），因此本研究通过构建置信带，对目标因果效应进行推断。

首先，本研究构造了两个极端的反事实目标人群数据集：

悲观集 ($\mathcal{H}_L$)：所有个体的 x_1 取值为 $\frac{(1)}{1} -$ （或分位数下界）；

乐观集 ($\mathcal{H}_H$)：所有个体的 x_1 取值为 $\frac{(1)}{1} +$ （或分位数上界）。

基于区间估计思想，本研究在反事实目标人群数据集构造的基础上，分别推导了因果效应的上下边界值。为确定因果效应的上下边界效应，需定义如下线性预测函数：

$$\tau(x_1, x_2) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots$$

则，可得因果效应下界（基于 $\mathcal{H}_L$ ）：

$$\tau_{=0} = \frac{1}{0} \left(\frac{1}{1 + \tau_{=0}(1, \frac{(1)}{1} - , 2)} - \frac{1}{1 + \tau_{=0}(0, \frac{(1)}{1} - , 2)} \right)$$

同时有如下因果效应上界（基于 $\mathcal{H}_H$ ）：

$$\tau_{h_h} = \frac{1}{0} \left(\frac{1}{1 + \tau_{=0}(1, \frac{(1)}{1} + , 2)} - \frac{1}{1 + \tau_{=0}(0, \frac{(1)}{1} + , 2)} \right)$$



最终构建得到如下 ACE 置信带：

$$[\min(\quad, {}_{h\ h}), \max(\quad, {}_{h\ h})]$$

Cox 比例风险模型推导

由于 Cox 模型中的 β_1 位于双重指数中 ($\exp(-\exp(\dots \beta_1 \dots))$)，无法通过均值插补解决。因此本研究采用了与 Logistic 模型下类似的估计策略：通过量化目标人群缺失变量 β_1 的不确定性，进而构造目标因果效应的分布边界。

首先，引入分布漂移参数： $\beta_1^{(0)} = [\beta_1^{(1)} - \delta, \beta_1^{(1)} + \delta]$ 。进而通过构建悲观集 ($\quad$) 和乐观集 ($\quad {}_{h\ h}$)，可分别计算得到如下生存曲线。

$$\text{下界: } (\quad) = \quad \quad \quad (\beta_1 = \beta_1^{(1)} - \delta, \dots)$$

$$\text{上界: } {}_{h\ h}(\quad) = \quad \quad \quad (\beta_1 = \beta_1^{(1)} + \delta, \dots)$$

最终两条生存曲线差值区间即目标 ACE 区间。

情形三：存在未观测效应修饰因子 U

当存在未观测变量 U ，且 U 在两群间分布不同时 ($[\beta_0] \neq$

$[\beta_1]$)，由于违反 S - admissibility 假设，常规估计过程就会有偏。

由于真实结构包含 U ，观测到的 (β_0, β_1) 实际上是对 U 的边缘化。

若 $(\beta_0 = 0) \neq (\beta_0 = 1)$ ，则边缘化后的效应也会不同。因此，

本研究首先定义如下整体偏倚参数

$$= ([\beta_0] - [\beta_1])$$

线性模型推导

真实结构模型假设下，包含 U 的真实数据生成机制可建模为：



$$= \beta_0 + \beta_1 Z + \beta_2 U + (\beta_3 Z + \beta_4 U) + \epsilon$$

其中 U 同时为效应修饰因子，即存在 交互项。

在此基础上，对 $S=1$ 人群，由于 U 未观测，因此拟合的模型实际上估计的是 U 的平均效应。那么对于给定的 Z ，试验样本中观测到的条件处理效应 $\tau_1(Z)$ 收敛于：

$$[\tau_1(Z)] = \beta_0 + \beta_1 Z + [\beta_2 U, U=1]$$

而目标 ACE 是基于目标人群 U 的分布：

$$\tau_0(Z) = \beta_0 + \beta_1 Z + [\beta_2 U, U=0]$$

进而可得如下偏倚函数，即两者的差值：

$$b(Z) = \tau_0(Z) - \tau_1(Z) = (\beta_2 [U, U=0] - \beta_2 [U, U=1])$$

定义敏感性参数 $\gamma = b(Z)$ ，最终可得如下目标因果效应推断公式：

$$\tau(Z) = \left(\frac{1}{0} \quad \gamma \right) +$$

Logistic 模型

在 Logistic 模型中，遗漏变量 U 不仅导致偏差，还因非线性导致系数缩放。具体而言，有如下 Logistic 模型。

$$(Y=1 | Z, U) = \beta_0 + \beta_1 Z + \dots + \beta_k U$$

在 Logistic 模型下，通常无法直接积分掉 U 。由于仅有 U 无法观测，因此有理由相信是 U 的分布差异导致了 Logit 尺度上的处理效应偏移。本研究通过引入偏倚函数来构造这种处理效应的偏移关系，即目标人群的 Log OR(Odds Ratio)与试验人群存在如下加性差异：

$$(Y=1 | Z=1, U=0) - (Y=1 | Z=0, U=0)$$



$$\approx [\quad (\quad = 1 \quad = 1, \quad , \quad = 1) - \quad (\quad = 1 \quad = 0, \quad , \quad = 1)] \\ +$$

其中 $\quad$ 代表了因 U 分布不同而导致的 LogOR 的加性偏倚。

进而在进行 G-computation 估计时,即可在预测目标人群 $\quad = 1$ 的风险过程中,引入偏倚项 $\quad$:

$$(\quad) = \frac{1}{0} \quad = 0 \left(\frac{1}{1 + \quad - (\quad , 1^+)} - \frac{1}{1 + \quad - (\quad , 0)} \right)$$

其中 $\quad , 1$ 是基于试验样本模型预测的 Logit 值。通过外部知识确定阈值,或在阈值无法确定情形下对 $\quad$ 进行数值扫描,即可评估未观测混杂对最终 ACE 推断结论(如是否跨越 0 点)的稳健性影响。

Cox 比例风险模型推导

假设未观测混杂 U 导致目标人群的基准风险或整体风险水平发生平移。在 Cox 比例风险模型中,这通常表现为对数风险(Log-Hazard)的加性偏倚 $\quad$ 。

$$h(\quad = 0) = h(\quad = 1) \exp(\quad)$$

在计算目标人群的累积风险时,乘上偏倚系数 $\quad$ 。

则,修正后的干预组生存率为:

$$(\quad (1), \quad) = [\quad (\quad (1))]^{\exp(\quad)}$$

修正后的对照组生存率为:

$$(\quad (0), \quad) = [\quad (\quad (0))]^{\exp(\quad)}$$

通过扫描 $\quad$ (例如 $\quad [-0.5, 0.5]$), 观察生存获益结论的稳健性。

针对试验样本只有 X, Z , 而目标人群样本具备 X, Y, Z 的数据情形(替代迁移)



当试验 ($Z = 1$) 只有替代终点 M (缺长期 Y); 而观察队列 ($Z = 0$) 有 M, Y (X 非随机), 这种情况下下目标估计量即试验的长期因果效应。

试验的长期因果效应估计需要完全中介假设, 即 $Y = f(X, M)$, 也就是 X 对 Y 的因果作用完全通过 M 介导。进而, 有如下非参数的反事实结局估计式

$$\begin{aligned} E(Y_1) &= E(Y | Z=1) = E(f(X, M) | Z=1) \quad (\text{全概率}) \\ &= E(f(X, M) | Z=0) \quad (\text{马尔可夫性}) \\ &= E(f(X, M=0) | Z=0) + E(f(X, M=1) | Z=1) \quad (\text{数据拼接}) \\ &\quad \text{观察队列估计} \quad \text{试验样本估计} \end{aligned}$$

进而, 在具体的模型设置下, 例如在线性模型下:

$$\begin{aligned} \text{RCT (试验样本): } Y_1 &= \beta_0 + \beta_1 X + \epsilon \\ \text{Obs (观察队列): } Y_0 &= \beta_0 + \beta_1 X + \epsilon \end{aligned}$$

有如下反事实结果:

$$E(Y_1 | Z=0) = E(\beta_0 + \beta_1 X | Z=0) = \beta_0 + \beta_1 E(X | Z=0)$$


最终可得如下因果效应估计:

$$\begin{aligned} \text{ATE} &= \frac{\partial E(Y)}{\partial Z} = \\ &= \beta_1 \end{aligned}$$

同时, 对二分类或多分类结局, 研究者常用如下 Logistic 模型:

$$\begin{aligned} \text{RCT: } Y_1 &= \text{logit}(\beta_0 + \beta_1 X + \beta_2 Z) \\ \text{Obs: } Y_0 &= \text{logit}(\beta_0 + \beta_1 X) \end{aligned}$$

则, 根据前门路径公式, 干预后的边际风险为如下积分形式:




由于 Logistic 函数与高斯分布的乘积没有解析解，且存在非线性偏差 $E[\sigma(\mathbf{w}^T \mathbf{x})] \neq \sigma(E[\mathbf{w}^T \mathbf{x}])$ ，因此必须采用数值模拟。在算法部分，本研究使用了蒙特卡洛 (Monte Carlo) 算法，其具体计算过程如下：

在观察数据中估计 θ_0 。

对照组 ($\alpha = 0$): 生成 $\binom{0}{0} = 1$ 个 $(0, 0)$ 。

$$(\quad = 1 \quad (\quad = 0)) \approx \frac{1}{\quad} \frac{1}{1 + \quad - (\quad_0 + \quad_0)} \quad$$
$$= (\text{ } = 1 \quad (\text{ } = 1)) - (\text{ } = 1 \quad (\text{ } = 0))$$



Cox 比例风险模型推导

Obs (结局模型 - Cox): $h(\cdot) = h_0(\cdot) \exp(\cdot)$

$$P(t) = \exp(-\Lambda_0(t)) \quad (t \geq 0, \quad \Lambda_0(0) = 0)$$

基于 RCT 参数, 生成 K 个虚拟中间变量:

将每个 β_j 代入观察队列的 Cox 模型，计算生存概率：

平均化:

计算 t 时刻的生存差 ((1)) - ((0))。

③ 多源 RCT 向同一目标人群迁移

当存在 K 个不同的 RCT 研究 ($k = 1, \dots, K$) 时,需将其证据综合迁移到同一个目标人群 ($k = 0$)。

情形一：一致性效应修饰

假设所有 RCT 与目标人群的条件生成机制相同，即满足 S-admissibility: