



项目批准号	62162005
申请代码	F0206
归口管理部门	
收件日期	



国家自然科学基金
资助项目结题/成果报告

资助类别： 地区科学基金项目

亚类说明：

附注说明：

项目名称： 图神经网络中的隐私保护理论和方法研究

负责人： 王金艳 BRID: 03078.00.10197

电子邮件: wangjy612@163.com 电话: 13557238790

依托单位: 广西师范大学

联系人: 唐琼琼 电话: 0773-3690052

直接费用: 36.0000 (万元) 执行年限: 2022.01-2025.12

填表日期： 2026年01月16日

国家自然科学基金委员会制（2025年）



项目摘要

中文摘要:

作为人工智能领域的一个新兴研究方向，图神经网络迅速崛起并已得到了广泛应用。由于图数据中包含大量的个人信息，图神经网络在为人们带来便利的同时也存在严重的隐私泄露风险。图数据具有不规则性且节点间关系复杂，这对现有的针对非图数据的深度学习隐私保护理论和方法提出了严重的挑战。本项目针对图神经网络中的隐私攻击和隐私保护技术展开研究。首先研究不同图数据、不同任务以及不同环境下训练图神经网络存在的隐私泄露问题，建立相应的攻击模型。然后针对集中式学习和联邦学习中图神经网络存在的隐私攻击，在权衡模型的隐私性、效用性和高效性的基础上，提出有效的隐私保护方法。同时研制原型系统验证模型和算法的性能，并促进成果在实际中的应用。项目的研究将为图神经网络提供系统的隐私保护理论和方法，力求突破隐私泄露对图神经网络应用的制约，促进人工智能的进一步发展，进而对经济发展和社会稳定具有重要的推动作用。

Abstract:

As a new research direction of artificial intelligence, graph neural networks are rising rapidly and have been widely applied in many fields. However, there are serious privacy leakage problems in graph neural networks while they bring convenience to people's daily life, because graph data contains a lot of personal information. Graph data is irregular and the relationship between nodes is complex, and the theories and methods of privacy protection for non-graph data cannot be applied in graph data. This project focuses on privacy attacks and privacy protection methods in graph neural networks. Firstly, we study the privacy leakage problems of training graph neural networks in different graph data, tasks and environments, and establish the corresponding attack models. Then, for solving the privacy attacks of graph neural networks in centralized learning and federated learning, some effective privacy protection methods are proposed by considering the tradeoff among privacy, utility and efficiency. Furthermore, we develop the prototype system to verify the performance of the models and algorithms, and promote the application of the research results. The project will offer systematic theories and methods for graph neural networks, strive to break through the restriction of privacy leakage on the application of graph neural networks, promote the further development of artificial intelligence, and then promote economic developments and social stability.

关键词（用分号分开）： 大数据隐私保护； 图神经网络； 机器学习； 差分隐私； 联邦学习

Keywords (separated by;): Privacy protection for big data; Graph neural network; Machine learning; Differential privacy; Federated learning



结题摘要

中文摘要（对项目的背景、主要研究内容、重要结果、关键数据及其科学意义等做简单概述）：

图神经网络作为人工智能领域的重要研究方向，在社交网络、推荐系统等领域得到广泛应用。由于图数据中包含大量的个人信息，图神经网络在为人们带来便利的同时也存在严重的隐私泄露风险。本项目针对图神经网络中的隐私攻击和隐私保护方法展开研究。主要研究内容包括：隐私攻击方法；集中式学习场景下的隐私保护方法；联邦学习场景下的隐私保护方法；图神经网络优化方法；对抗攻击与防御方法。依托本项目发表学术论文18篇，其中SCI收录10篇，EI收录18篇。获发明专利授权1项，受理4项，获得软件著作权4项。项目所取得的研究成果如下：(1)在隐私攻击方面，提出面向跨域图攻击的分布外成员推理攻击方法和预算有限条件下的模型窃取攻击方法，分析动态图神经网络中存在的隐私泄露问题，并对药品不良反应自发报告系统中存在的隐私问题进行研究；(2)在集中式场景下的隐私保护方面，提出差分隐私监督图稀疏化学习方法、结构熵优化的差分隐私图结构学习方法、具有语义感知的差分隐私图神经网络学习方法及基于差分隐私的随机森林方法；(3)在联邦学习场景下的隐私保护方面，提出基于知识校准的联邦图学习方法、基于梯度聚合校准的联邦图学习方法、基于知识蒸馏和对比学习的联邦图学习方法、基于知识解耦和个性化聚合的模型异构联邦图学习方法及节点增强的联邦异质图学习方法；(4)在图神经网络优化方面，提出对抗信息补全的图神经网络模型、融合结构与节点知识的高效蒸馏方法、鲁棒图对比学习方法和基于高匹配性非同质关系的动态社交推荐方法；(5)在对抗攻击与防御方面，提出拓扑感知节点注入攻击方法、简单有效的图注入攻击防御方法、基于后验分布对齐的图防御方法、个性化的图通用防御方法以及结构互补的超图防御框架。项目成果为图神经网络提供系统的隐私保护理论和方法，将促进人工智能的进一步发展，进而对经济发展和社会稳定具有重要的推动作用。

Abstract (Brief description of research background, main methods, contributions, and research data):

Graph neural networks (GNNs) have emerged as an important research direction in artificial intelligence and have been widely applied in domains such as social networks and recommendation systems. While GNNs provide significant convenience, they also raise serious risks of privacy leakage as graph-structured data inherently contains a lot of personal information. This project focuses on the study of privacy attacks and privacy protection methods in GNNs. The main research contents include: privacy attack methods; privacy protection methods in centralized learning; privacy protection methods in federated learning; optimization methods for GNNs; and adversarial attack and defense methods. Based on this project, 18 academic papers have been published, including 10 indexed by SCI and 18 indexed by EI. In addition, 1 patent has been granted, 4 patents have been handled, and 4 software copyrights have been obtained. The research results are summarized as follows. (1) For privacy attack methods, we propose an out-of-distribution membership inference attack focused on cross-domain graph attacks and a model extraction attack under limited query budgets. We further analyze privacy leakage issues in dynamic GNNs and investigate privacy concerns in spontaneous reporting systems for drug adverse reaction. (2) For privacy protection methods in centralized learning, we develop a differential private supervised graph sparsification learning method, a differential private graph structure learning approach based on structural entropy optimization, a semantics-aware differential private graph neural network learning framework, and differential private random forest method. (3) For privacy protection in federated learning, we propose a logit calibrated federated graph learning approach, a federated graph learning method based on gradient aggregation calibration, federated graph learning frameworks based on knowledge distillation and contrastive learning, a federated graph learning method for heterogeneous models based on knowledge decoupling and personalized aggregation, and a node-enhanced federated heterogeneous graph learning method. (4) For graph neural network optimization methods, we develop a



graph neural network model with adversarial information completion, an efficient distillation method integrated structural and node knowledge, a robust graph contrastive learning approach, and a dynamic social recommendation method with high-matching inhomogeneous relations. (5) For adversarial attacks and defenses, we propose a topology-aware node injection attack, a simple yet effective defense against graph injection attacks, a graph defense method based on posterior distribution alignment, a personalized universal graph defense framework, and a structural complementary hypergraph defense framework. This project provides a systematic theoretical foundation and methods for privacy protection in GNNs, which will promote further advances in artificial intelligence and make significant contributions to economic development and social stability.

关键词（用分号分开）： 图神经网络； 隐私攻击； 隐私保护； 差分隐私； 联邦学习

Keywords (separated by;)： Graph Neural Networks; Privacy Attacks; Privacy Protection; Differential Privacy; Federated Learning



正文

(一) 结题部分

1. 研究计划执行情况概述。

(1) 按计划执行情况。

本项目按照预定计划开展研究工作，对图神经网络中的隐私问题展开研究，分析训练图神经网络存在的隐私泄露问题，并针对集中式学习和联邦学习场景，提出有效的隐私保护方法。此外，本项目还对图神经网络的性能优化及对抗攻击和防御方法进行探讨。顺利完成项目任务书中的研究内容：1) 图神经网络的隐私攻击方法研究；2) 集中式学习场景下图神经网络隐私保护方法研究；3) 联邦学习场景下图神经网络隐私保护方法研究。

项目依托广西师范大学计算机科学与工程学院、教育区块链与智能技术教育部重点实验室和广西多源信息挖掘与安全重点实验室，在广西师范大学科技处、财务处等相关部门的监督和指导下，按照国家自然科学基金管理办法和学校相关管理办法开展工作。

(2) 研究目标完成情况。

项目研究图神经网络中的隐私保护问题，通过研究图神经网络中的隐私攻击与保护技术为图深度学习模型提供系统的隐私保护理论和方法。具体目标为提出有效的隐私攻击和隐私保护方法，并开发程序以验证算法的性能。在相关领域的重要期刊或会议上发表高质量论文8-12篇，申请发明专利3项，计算机软件著作权1项。培养青年教师3名，硕士研究生6名。

在本项目的支持下，项目组人员积极开展相应的研究工作，取得了一系列研究成果。依托本项目，发表论文18篇，其中SCI检索10篇(SCI一区论文4篇，SCI二区论文3篇)，EI检索18篇，中国计算机学会(CCF)推荐A类会议论文1篇，B类期刊/会议论文6篇，C类期刊/会议论文10篇。获发明专利授权1项，受理4项，获得软件著作权4项。培养青年教师3名，硕士研究生18名。

综上所述，本课题组已按计划完成研究任务，并完成成果指标要求。

2. 研究工作主要进展、结果和影响。

(1) 主要研究内容。

按照项目申请书的研究内容，本项目对图神经网络中的隐私保护问题展开研究，同时还对图神经网络的性能优化及对抗攻击和防御方法进行探讨。图神经网络的优化既可能强化数据记忆、扩大隐私攻击面，也能通过轻量化、正则化等手段，降低隐私保护的性能损耗；隐私攻防关注敏感信息防泄露，对抗攻防聚焦模



型功能防破坏，二者既相互赋能，又可能彼此引入新的安全威胁，协同融合才能构建图神经网络的安全体系。主要研究内容如下：

1) 在隐私攻击方面，分析现有成员推理攻击在跨域场景因分布偏移导致攻击失效问题，提出面向跨域图攻击的分布外成员推理攻击方法；通过语义分析获得额外背景知识，提出具有语义增强的成员推理攻击；针对查询预算有限问题，提出预算有限条件下的模型窃取攻击方法；通过对比节点不同时刻的特征信息，分析动态图神经网络中存在的隐私泄露问题。此外，对药品不良反应自发报告系统中存在的隐私问题进行研究，提出多种隐私攻击，包括连续性攻击、复发攻击、完全停药攻击等。

2) 在集中式场景下的隐私保护方面，针对敏感图拓扑和节点特征泄露的问题，提出差分隐私监督图稀疏化学习方法；针对图结构学习存在的隐私泄露问题，提出结构熵优化的差分隐私图结构学习方法；针对异质图数据中存在的隐私问题，提出具有语义感知的差分隐私图神经网络学习方法。此外，针对随机森林中存在的隐私泄露问题，提出基于差分隐私的随机森林方法。

3) 在联邦学习场景下的隐私保护方面，针对客户端类不平衡问题，提出基于知识校准的联邦图学习方法；针对非独立同分布和长尾分布问题，提出梯度聚合校准的联邦图学习方法；针对分子图结构数据分布的异质性问题，提出基于知识蒸馏和对比学习的联邦图学习方法；针对模型异构问题，提出基于知识解耦和个性化聚合的模型异构的联邦图学习方法；针对异质图数据稀疏和类别不平衡问题，提出节点增强的联邦异质图学习方法。

4) 在图神经网络优化方面，为使图神经网络更好地处理低度节点以及节点特征缺失问题，提出对抗信息补全的图神经网络模型；针对图神经网络聚合的可扩展性限制及知识蒸馏中固有结构偏差问题，融合结构与节点知识等实现高效蒸馏；针对标签稀疏且含有噪声的问题，提出鲁棒图对比学习方法；针对多关系类型的高阶交互中用户兴趣或项目吸引力的时序性及其存在的非同质性影响，提出有效的社交推荐方法。

5) 在对抗攻击与防御方面，为提升攻击的有效性和可扩展性，提出拓扑感知节点注入攻击方法；针对防御模型无法抵御高隐蔽性的图注入攻击问题，提出简单有效的图注入攻击防御方法；针对全局攻击中图防御跨攻击下的脆弱性问题，提出基于后验分布对齐的图防御方法；针对局部攻击中图防御统一看待目标节点导致的脆弱性问题，提出个性化的图通用防御方法；针对超图神经网络的高阶依赖建模能力使其易受结构攻击的问题，提出结构互补的超图防御框架。

(2) 取得的主要研究进展、重要结果、关键数据等及其科学意义或应用前景。



1) 隐私攻击方法

对于图神经网络面临的隐私安全威胁,分析现有成员推理攻击严重依赖同分布辅助数据、在跨域场景下因分布偏移导致攻击失效的问题,提出面向跨域图攻击的分布外成员推理攻击方法。首先在影子模型训练阶段,设计基于环境构建的不变性学习机制:通过数据增强,构建多个训练环境,并结合图信息瓶颈与不变风险最小化联合优化,旨在从不同环境中提取能够抵抗分布变化的跨域不变特征和关键拓扑结构,消除环境带来的混淆影响。进而为提高攻击推理在未知目标域的适应性,在攻击模型训练阶段,引入风险外推策略。该机制通过惩罚不同环境间的风险方差来平衡训练风险,促使攻击模型学习到鲁棒的攻击模式,从而在分布发生偏移时仍能保持稳定的攻击性能。在多个不同规模和属性的数据集上进行了大量的实验,结果表明该算法在跨域设置下的攻击性能显著优于现有基准方法。

从图数据的异质性和拓扑的层次性探讨图神经网络中的隐私保护问题,针对异质社交网络中的隐私泄露场景,揭示与异质性相关的隐私泄露风险。定义具有语义增强的成员推理攻击,该攻击可以利用社交图数据中用户之间的社交关系和交互历史,即样本之间的语义相似性和相关性,通过语义分析获得额外的背景知识来增强成员推理攻击成功的概率。分析动态图神经网络存在的隐私问题,指出在节点信息传递阶段,攻击者可以通过对比节点不同时刻的特征信息得到节点的传递信息,并结合一定的背景知识推断出动态图中边的隐私信息。

针对现有模型窃取方法在实际应用中往往忽略查询预算有限性的问题,提出由节点选择与模型训练模块组成的模型窃取攻击方法。在节点选择模块中,首先在有限查询预算与固定批量大小约束下构建候选节点集,并结合代理模型预测不确定性与节点 PageRank 结构重要性对候选节点进行联合评估;随后引入基于嵌入空间分布的密度感知筛选策略,在满足批量大小约束的前提下选取具有代表性且多样性的节点,以减少冗余查询并提高单轮选择效用。在模型训练模块中,利用所查询节点对代理模型进行迭代更新,引入基于特征掩码的数据增强,并基于目标模型输出设计一致性约束损失,通过正则化使得代理模型在特征扰动下保持预测一致,提升表示鲁棒性。实验结果表明,该方法在预算有限的情况下能够有效提升模型窃取下代理模型的性能。

此外,对药品不良反应自发报告系统中存在的隐私问题进行研究,提出多种隐私攻击:连续性攻击、复发攻击、完全停药攻击、旧记录攻击以及完全特定轨迹攻击。其中,掌握目标在所有时期完整出现模式的完全特定轨迹攻击是威胁性最强的攻击。这些攻击可归纳为一个通用模型—轨迹攻击,即攻击者利用目标的轨迹模式结合准标识符来定位目标的记录。

2) 集中式学习场景下的隐私保护方法



对于监督图稀疏化,分析其在提升图神经网络计算效率的同时存在敏感图拓扑和节点特征泄露的隐私问题,提出差分隐私监督图稀疏化方法。首先在训练过程中设计双层防御机制:自适应拓扑隐私层和分层特征隐私层。进而为提高图学习任务在连续训练过程中的数据效用性,在梯度处理模块中设计三阶段机制:分层梯度剪裁阶段、差异化高斯加噪阶段以及基于信噪比的自适应调整阶段。为减少标准采样导致的梯度饱和与收敛波动,在梯度处理阶段根据边缘得分与采样掩码之间的关系设计差异化计算公式,以决定是采用较大的探索步幅还是更精确的近似更新。当进入自适应拓扑扰动阶段时,算法利用多头注意力机制筛选边缘分数候选集并注入校准高斯噪声,以生成隐私稀疏邻接矩阵。最后在多类图数据集上的实验验证了该方法的有效性和效率。

针对图结构学习中存在的隐私泄露问题,提出融合自适应差分隐私与结构熵的隐私增强图结构学习方法,以实现隐私保护与结构学习的协同优化。首先对节点原始特征矩阵进行扰动,结合 Pearson 相关系数构建 k 近邻图并与原始图融合,引入成员推理攻击风险正则化确定最优 k 值,完成隐私增强图构建;其次,设计自适应差分隐私编码树方案,基于社区重要性动态分配隐私预算,对结构熵贡献进行扰动,实现层级划分与社区关系的隐私保护;最后,通过温度控制采样机制,依据层级结构推导熵动态调整采样分布,完成鲁棒且可控的图拓扑重构。为缓解隐私保护与数据效用的冲突,在特征扰动与结构熵优化阶段设计针对性差异计算逻辑,通过双阶段差分隐私机制协同防护属性隐私与结构隐私。实验结果表明,在合理隐私预算下,该方法分类性能与主流图结构学习方法相当。

针对异质图数据中存在的隐私攻击问题,提出具有语义感知的差分隐私图神经网络学习方法。特征注意扰动机制利用异质注意机制来学习和扰动节点表示,扰动程度取决于特征级高斯噪声的敏感度,并受到不同类型邻居和关系的影响。具体而言,模型根据代表语义信息的元路径来构建节点邻居,并进行语义注意力去偏,因为构建过程会损失一部分的语义信息。拓扑梯度扰动机制将扰动后的节点表示输入到异质变分图自编码器中,用于重构保护隐私的拓扑结构,其中包含一个正则化项作为额外的语义关系的软监督目标。即在链接预测时设置了可学习的梯度剪裁超参数作为噪声敏感度,以剪裁和扰动梯度。最后,为更好地整合这两种特性,使用双层优化机制来实现隐私保护和性能优化之间的权衡,并合理分配隐私预算。最后在经典的异质图数据集上验证该方法的性能。

此外,针对随机森林算法所面临的隐私泄露风险和分类准确性之间的矛盾,提出基于差分隐私的两阶段随机森林构造方法。首先,在构造决策树时对二分类和多分类问题统一建模,利用指数机制和拉普拉斯机制对非叶子节点和叶子节点进行扰动,并设计有效的隐私预算分配策略来缓解节点的信噪比不平衡问题。然



后,为提高决策树之间的互补性提出两阶段的随机森林构造方法。实验结果表明该方法在保证隐私的同时有较高的分类准确率。

3) 联邦学习场景下的隐私保护方法

针对图数据上的联邦学习中存在的类别高度不平衡问题,提出基于知识校准的联邦图学习方法。该方法通过在本地客户端引入 GraphSage 模型和 Mixup 技术(即 sageMixup 模型)来有效利用图的结构和特征信息,生成增强的节点表示。sageMixup 模型中的 Mixup 过程还能产生匿名化的节点表示,使得潜在攻击者难以识别出敏感信息,从而在增强隐私保护的同时,提高模型的泛化能力。为在中央服务器上构建能够应对客户端类别不平衡问题的全局模型,首先,接收所有由客户端上传的匿名节点嵌入,同时利用节点嵌入拼接策略生成全局节点嵌入。然后,通过层级注意力算法对模型参数进行聚合,并利用全局节点嵌入对模型进行重训练,生成微平衡知识。同时,在服务器定义集成模型,用知识校准方法获得校准后的知识。最后,利用自适应校准算法高效地融合微平衡和校准后的知识,从而在联邦图学习中获得更好的性能。

针对联邦图学习中数据非独立同分布与长尾分布问题,分析现有方法因依赖类别分布平衡假设,在现实长尾场景下易偏向头部类别、全局性能不佳的缺陷,经实验验证特征结构解耦与自适应梯度聚合校准策略的有效性后,提出基于梯度聚合校准的联邦图学习方法。具体而言,客户端本地训练阶段采用特征-结构解耦图注意力网络,引入类别重要性平衡策略缓解类别不平衡,通过知识重学习增强泛化性能。本地训练完成后,考虑到各客户端类别不平衡程度差异,直接聚合易致全局模型偏差,故在全局聚合阶段采用自适应梯度聚合策略,根据客户端数据类别不平衡程度动态调整平衡因子优化聚合,并利用全局类别梯度校准可学习特征。中央服务器接收各客户端梯度信息后,经上述聚合得到全局模型参数,指导本地模型更新。最后在高度非独立同分布与长尾分布数据集上的大量实验,验证了该方法的有效性。

针对分子图结构数据分类场景,发现客户端的图数据之间在结构和特征上均呈现出一定程度的异质性,为实现模型个性化以达到高性能的模型分类结果,提出基于知识蒸馏和对比学习的联邦图学习方法。首先对各个客户端上传的图嵌入进行聚类,使服务器的分类模型更易收敛,之后在每个簇中的客户端和服务端之间交互过程时分别迁移知识。客户端将本地知识与当前簇返回的知识一起作为正样本,与其它簇中的知识一起作为负样本,从而构造的对比学习去进一步增强客户端图嵌入的学习能力。同时分析了联邦图分类框架中各部分隐私泄露的风险和威胁,提出自适应本地化差分隐私来保护客户端与服务端交互过程中的隐私数据。最后在数据集上验证该方法可以获得比基线更好的结果,且能平衡模型效用性和



数据的隐私性。

对于模型异构场景下联邦图学习的节点分类任务,分析其现有基于嵌入原型工作因全局聚合不兼容导致效果不佳的问题,提出基于 logits 原型解耦和个性化的联邦图学习方法。首先,通过实验和理论分析发现基于嵌入原型在模型异构联邦图场景中存在表示空间不兼容效果不佳的问题,并进一步发现基于 logits 原型因其具有对齐的共享语义空间,能获得较好的效果。基于这一核心发现,首先通过结构、嵌入和语义三个维度加权生成代表性 logits 原型代替传统的平均聚合,并且通过个性化知识解耦将代表性 logits 原型来分解出协作 logits 原型上传至服务器。服务器端构建协作图,通过协作图来反映不同客户端的协作强度由此来生成个性化的全局原型来指导各客户端本地模型的更新。最后在图数据集上进行大量的实验来表明该算法的有效性和可扩展性。

针对异构图节点分类任务,分析集中式训练隐私泄露及分布式场景下数据不平衡、私有边类型处理难题,提出面向隐私保护的联邦异构图学习框架。具体而言,各客户端本地设计边缘类型感知编码与自适应异构图重构双模块增强机制,以缓解本地数据稀疏性。为提升全局模型的收敛性与表征一致性,联邦训练采用三阶段协同流程:本地特征增强与训练、边缘类型敏感参数分解、全局参数对比对齐与加权聚合。参数上传阶段,依据边类型公私属性实施参数分解,有效减少冗余传输与计算开销;全局聚合阶段则通过对比学习对齐本地与全局表征。为获取隐私安全的节点表征,经本地增强模块缓解数据稀疏性后,由本地模型融合多类型信息并仅上传公共属性参数。最后在异构图数据集上进行大量实验,从分类性能、隐私安全性及执行效率多维度验证了框架的有效性。

4) 图神经网络优化方法

图神经网络在与图相关的任务中表现出优异的性能,然而目前图神经网络的研究主要集中于提出新的图神经网络模型或修改现有模型以提高图相关任务的性能,很少考虑作为模型输入的图数据中可能存在的问题。为使图神经网络更好地处理低度节点,提出对抗信息补全的图神经网络模型,该方法引入了图信息生成器和图嵌入鉴别器,分别用于自适应拟合节点缺失信息的分布和区分具有理想信息的节点嵌入和经过信息补全的节点嵌入。生成器和鉴别器之间的对抗训练增强了整个模型的表示能力。同时,还采用双重节点嵌入对齐机制来指导生成高质量的缺失信息。进而,考虑图神经网络中图节点特征部分缺失或者完全缺失的问题,提出特征信息生成器用于模拟节点嵌入中可能缺失的信息,并引入两种对齐机制用于限制生成更准确的缺失信息。该方法是模型无关的通用方法,可与现有的各种图神经网络相结合。

针对图神经网络到多层感知机知识蒸馏中普遍存在的监督退化问题,首先指



出现有方法过度依赖邻域聚合得到的结构知识,进一步分析在低局部同质性区域容易引入结构偏置,从而削弱蒸馏监督的有效性;同时,静态且粗粒度的蒸馏策略难以充分刻画节点层面的置信度差异与教师预测在训练过程中的动态变化。为此提出置信引导的自适应知识蒸馏框架,通过自适应融合结构知识与节点级知识,在蒸馏阶段缓解结构异质性对监督信号质量的负面影响;进一步基于 Top- k 预测分布构建置信度引导的学习机制,强化高置信类别的判别性约束并抑制低置信类别的干扰;同时引入动态知识更新策略,使蒸馏监督能够随学生模型训练过程逐步对齐。大量实验结果表明,该方法在保持多层感知机推理效率下,有效提升了学生模型在不同结构可靠性区域上的预测性能与稳定性。

针对标签稀疏和标签噪声的图节点分类问题,提出鲁棒图对比学习框架。首先为缓解有限监督信号带来的表征退化,引入自监督对比损失挖掘无标签节点中的潜在语义信息,从而提升表示的判别性与鲁棒性。进而为利用图结构中的同质性特征,设计弱监督对比损失,将邻居节点视为正样本并施加邻居一致性约束,以增强局部结构平滑性。其次,针对对比学习数据增广和图神经网络的脆弱性提出动态交叉熵损失,缓解模型对标签噪声的过拟合。最后,考虑不同损失优化目标可能引入的特征语义偏差,构建跨空间一致性约束以对齐多种表示空间,增强其内在语义一致性。该框架同时利用无标签数据中的潜在语义信息与图结构中的邻域一致性约束,并有效缓解噪声标签对模型影响,学习到更可靠的节点表示。实验结果验证该方法的在标签稀疏且含噪场景下的有效性和鲁棒性。

针对现有基于图神经网络的社交推荐方法未能细粒度地考虑在多关系类型的高阶交互中,用户兴趣或项目吸引力随时间的变化以及非同质性影响的问题,提出基于高匹配性非同质关系的动态社交推荐方法,从多个角度揭示动态交互中的非同质性对社交推荐的影响。首先利用长短期记忆和图注意力网络,对来自社交网络 and 用户-项目交互的多种关系类型的短期动态以及长期静态表示进行建模。然后将用户的两种高阶关系对目标用户的兴趣影响和高阶相关项目对目标项目的吸引力影响,分别建模为用户和项目的图增强表示。接着利用图增强表示从交互历史中提取最相关的信息,以防止目标用户或候选项目仅具有有限的交互历史。最后,结合用户和项目的最终潜在因素,利用多层感知机进行推荐预测任务。在基准数据集上的实验结果表明,与现有基线相比,该方法具有较优的性能。

针对动态图子图级异常检测问题,提出基于时空自编码器的无监督异常检测方法。该方法使用时间窗口在离散动态图数据流中学习图的演化模式,并在每个时间窗口中设置动态锚点,提供时空位置信息。然后,基于拓扑预测和属性重建构建残差图,以在被检测快照下捕获异常子图。在无监督学习中,通过最小化属性重建和拓扑预测中的损失,模型能够捕获的子图异常模式与正常模式的差异。



该方法在图快照中引入动态锚点,以获取每个节点的全局位置信息和时间相对位置。这有助于在图中重建正常区域,增强模型对异常区域的识别。最后,设计异常动态子图的注入方法,并在数据集进行大量实验,验证算法在动态图子图级异常检测的能力。

5) 对抗攻击与防御方法

针对现有节点注入攻击方法在攻击效果和可扩展性方面的局限性,提出拓扑感知节点注入攻击方法,旨在兼顾攻击有效性与计算可扩展性。该方法由双阶段拓扑构建策略和自适应特征优化模块两部分组成。在拓扑构建阶段,首先基于节点的信息感知能力,筛选感知能力较弱的节点作为候选邻居集,从而缩小注入节点的拓扑搜索空间并降低计算开销。然后,根据最佳错误类一致性原则,为注入节点生成并优化其连接结构,使攻击扰动在有限预算内对目标模型产生更强的误导效应。在完成拓扑构造后,对恶意注入节点的特征进行自适应优化,从而增强其在表示学习和预测阶段中的攻击影响。实验结果表明,所提方法比现有的节点注入攻击方法取得更强的攻击效果,并保持了大规模场景下的可扩展性。

针对现有图神经网络防御方法对高隐蔽节点注入攻击防御能力不足的问题,提出基于邻居影响评估的节点注入攻击防御方法。该方法首先在扰动图上利用已训练好的图神经网络提取节点的基础表示,并进一步通过消息传递获得融合邻居信息的聚合表示。随后对比节点在消息聚合前后对其邻居表示产生的变化,评估每条连接在信息传播过程中所引入的异常影响,并结合邻居结构规模刻画边级影响强度。在此基础上,从节点视角汇总其邻域内的异常影响,计算节点的整体异常程度,以识别对周围节点产生显著干扰的潜在注入节点。最后,根据异常程度筛选出可疑的恶意注入节点,并切断其与正常节点之间的连接关系,从而有效阻断错误信息在图中的传播。实验表明,所提方法能够有效识别并移除高隐蔽的注入节点,从而显著提升模型对节点注入攻击的鲁棒性。

针对现有图神经网络容易受结构攻击影响、且现有启发式防御方法缺乏普适鲁棒性的问题,提出结合非平滑消息传递与分布偏移约束的鲁棒性增强方法。首先从后验分布的角度讨论了图神经网络在结构扰动下的异常行为,指出图神经网络的结构脆弱性源于它们对局部图平滑的依赖,图平滑还可能导致模型无法拟合。为从本质上预防模型产生异常行为,提出非平滑消息传递,以提高对结构扰动的容忍性,同时减轻无法拟合现象;此外,提出分布偏移约束来削弱其他异常行为带来的影响。该方法在四种攻击和六个不同数据集上,与 11 个具有代表性的基线进行了比较,结果表明对于各种攻击的防御性能均有提升,并在准确性和对抗鲁棒性之间取得了良好的平衡。

针对当前超图神经网络在结构攻击场景下鲁棒性不足的问题,提出基于结构



互补的超图防御框架。在训练阶段，该方法联合训练互补结构依赖分支，其中深层结构依赖分支通过多轮消息传递捕获超图结构中的高阶语义信息，浅层结构依赖分支则减少对超边的依赖以降低对结构扰动的敏感性。然后，采用超边级对比学习机制，将深层分支所学习到的高阶语义知识迁移至浅层分支。为消除不可靠连接，进一步设计基于加权团扩展与特征相似性过滤的结构净化策略。在净化后的超图上，引入预测平滑正则化，促使语义相似且结构紧密的节点在预测上趋于一致。在推理阶段，该方法仅使用浅层分支以保证结构鲁棒性与计算效率。实验结果表明，与现有超图神经网络基线方法相比，所提方法能够在保持高阶表示能力的同时显著提升模型的结构鲁棒性。

针对异质图神经网络在结构对抗攻击下鲁棒性显著下降的问题，系统分析其面临的三类脆弱性：扰动传播效应、重要语义关系破坏以及结构一致性漂移。提出语义净化与结构一致性协同的鲁棒防御方法，实现对复杂结构扰动的双重建模。首先基于多元路径构建多语义视图，通过语义感知的边加权机制对边可靠性进行动态评估，从而抑制对抗边与冗余边，并强化语义重要但结构脆弱的连接，实现自适应全局结构净化。进而为缓解跨视图结构一致性漂移，引入结构感知的对比优化模块，将全局净化视图与局部扰动视图构建为自监督对比对齐目标，引导模型学习对局部结构扰动具有不变性的鲁棒表示。实验结果表明，在投毒攻击与逃逸攻击场景下，该方法在多个数据集及不同攻击强度条件中均显著优于现有防御方法。

3. 研究人员的合作与分工。

项目组经过四年的合作，有4名教师、18名硕士研究生先后参与了本项目的研究工作，主要研究人员包括：

王金艳，项目负责人，承担的主要工作包括对项目的规划和组织管理，合理安排研究任务，研究图神经网络中的隐私攻击、集中式学习和联邦学习场景下的隐私保护方法，以及图神经网络优化方法和对抗攻击与防御方法，指导软件的设计与实现。

石贞奎，副教授，承担项目参加人员的组织管理以及隐私保护方法研究。

周飞燕、徐鲁辉，副教授，承担研究生的组织与管理，指导算法设计与编码实现。

杨柳、薛颖宏，硕士研究生，承担图神经网络中的隐私攻击方法研究，以及算法的编码与实现。

郭辰豪、司家璇、韦岳岑，硕士研究生，承担集中式图神经网络隐私保护方法研究，以及算法的编码与实现。



颜东琪、宁杨友、邓荣斌、李婕、余晓阳，硕士研究生，承担联邦图神经网络隐私保护方法研究，以及算法的编码与实现。

徐华泽、潘志洋、杨汉钦，硕士研究生，承担动态图神经网络的优化、隐私攻击和保护方法的研究，以及算法的编码与实现。

韦全敏、胡俊、李胜寒，硕士研究生，承担图神经网络优化方法的研究，以及算法的编码与实现。

苏琳琳、赵崇洁、左京，硕士研究生，承担图神经网络对抗攻击与防御方法研究，以及算法的编码与实现。

胡宇航、刘松逢、李德三名硕士研究生，因研究生毕业退出。

4. 国内外学术合作交流等情况。

- [1] 2022 年 6 月 25，王金艳线上参加图机器学习在线峰会。
- [2] 2022 年 7 月 22-25 日，宁杨友参加在广州举行的中国计算机应用大会。
- [3] 2022 年 12 月 16-18 日，胡俊线上参加在北京举行的 CCF 学科前沿讲习班 ADL137 联邦学习与隐私计算。
- [4] 2022 年 11 月 18-19 日，王金艳参加在桂林举行 The 21st International Workshop on Digital-forensics and Watermarking (IWDW 2022)。
- [5] 2023 年 6 月 25-27 日，李胜寒线上参加在北京举行的 CCF 学科前沿讲习班 ADL140 鲁棒机器学习。
- [6] 2023 年 8 月 16-18 日，胡俊线上参加在广州举行的 International Conference on Knowledge Science, Engineering and Management (KSEM 2023)，发表 1 篇学术论文，并做了相关报告。
- [7] 2023 年 9 月 26-29 日，颜东琪、宁杨友线上参加在伊拉克利翁举行的 The 32nd International Conference on Artificial Neural Network (ICANN 2023)，发表 2 篇学术论文，并做了相关报告。
- [8] 2023 年 10 月 1-4 日，李胜寒线上参加在夏威夷举行的 IEEE International Conference on Systems, Man, and Cybernetics (SMC 2023)，发表 1 篇学术论文，并做了相关报告。
- [9] 2023 年 11 月 1-3 日，苏琳琳线上参加在埃克塞特举行的 The 22nd IEEE International Conference on Trust, Security and Privacy in Computing and Communications (TrustCom 2023)，发表 1 篇学术论文，并做了相关报告。
- [10] 2024 年 4 月 26-28 日，邓荣斌、杨柳参加在宁波举行的第十七届中国电子信息年会。
- [11] 2024 年 7 月 5-7 日，王金艳、苏琳琳参加在长沙举行的 2024 中国图灵大会。



- [12]2024 年 10 月 24-26 日, 赵崇洁、郭辰豪、司家璇参加在横店举行的 2024 中国计算机大会。
- [13]2024 年 10 月 30-11 月 2 日, 邓荣斌参加在开封举行的 The 22nd IEEE International Symposium on Parallel and Distributed Processing with Applications (ISPA 2024), 发表 1 篇学术论文, 并做了相关报告。
- [14]2025 年 6 月 7-8 日, 苏琳琳参加在北京举行的 CCF 首届图机器学习会议。
- [15]2025 年 7 月 18-20 日, 王金艳参加在桂林举行的大数据与人工智能科学大会。
- [16]2025 年 7 月 31-8 月 3 日, 王金艳、左京参加在昆明举行的中国计算机学会人工智能会议。
- [17]2025 年 8 月 29-31 日, 杨柳、司家璇、郭辰豪参加在广州(分会场)举行的 The 34th International Joint Conference on Artificial Intelligence (IJCAI 2025), 发表 1 篇学术论文, 并做了相关报告。
- [18]2025 年 9 月 19-21 日, 余晓阳参加在北京举行的 CCF 学科前沿讲习班 ADL163 联邦大模型。
- [19]2025 年 10 月 11-12 日, 薛颖宏参加在深圳举行的 ACM 中国图灵大会。
- [20]2025 年 11 月 7-8 日, 王金艳参加在桂林举行的新一代图像安全技术研讨会。
- [21]2025 年 11 月 11-13 日, 赵崇洁线上参加在韩国首尔举办的 The 34th ACM International Conference on Information and Knowledge Management (CIKM 2025), 发表 1 篇学术论文, 并做了相关报告。
- [22]2025 年 12 月 5-7 日, 王金艳参加在海口举行的网络空间安全学术会议。

5. 存在的问题、建议及其他需要说明的情况。

经过项目组成员的共同努力, 本项目的研究任务得以顺利完成, 并超额完成成果指标。通过本项目的研究, 项目组在图神经网络中的隐私保护研究上积累了丰富的经验, 对其它领域的隐私保护问题研究打下了坚实的基础, 下一步将对大模型中的隐私保护问题展开研究。

(二) 成果部分

1. 项目取得成果的总体情况。

本项目累计发表或录用论文 18 篇, 其中 SCI 期刊论文 10 篇, EI 期刊或会议论文 18 篇, CCF 推荐 A 类会议论文 1 篇, B 类期刊/会议论文 6 篇, C 类期刊/会议论文 10 篇。获发明专利授权 1 项, 受理 4 项, 获得软件著作权 4 项。培养培养青年教师 3 名, 硕士研究生 18 名。



2. 项目成果转化及应用情况。

项目的研究成果对于电子商务、社交网络等图数据共享中个人隐私保护具有重要的应用前景。目前获发明专利授权 1 项，受理 4 项，获得软件著作权 4 项。尚未有成果转化及应用情况。

3. 人才培养情况。

项目负责人于 2024 年 9 月入选为八桂青年拔尖人才；项目组核心成员石贞奎、周飞燕、徐鲁辉晋升为副教授。依托本项目，培养硕士研究生 18 名，已毕业 10 名，在读 8 名，如下表所示。

姓名	研究方向	论文题目	导师	答辩/预计日期
韦岳岑	图神经网络 数据安全	面向社交网络的差分隐私图神经网络学习方法研究	王金艳	2023 年 6 月
徐华泽	图神经网络 数据安全	基于动态图神经网络的隐私保护方法研究	王金艳	2023 年 6 月
韦全敏	图神经网络	面向图神经网络的信息增强方法研究	王金艳	2023 年 6 月
颜东琪	图神经网络 数据安全	面向类不平衡图数据的图联邦学习方法研究	王金艳	2024 年 6 月
宁杨友	图神经网络 数据安全	面向隐私保护的图联邦学习方法研究	王金艳	2024 年 6 月
苏琳琳	图神经网络 数据安全	图神经网络注入攻击和防御方法研究	王金艳	2024 年 6 月
胡俊	图神经网络	面向属性缺失数据的图神经网络学习方法研究	王金艳	2024 年 6 月
李胜寒	图神经网络	基于图神经网络的社交推荐方法研究	王金艳	2024 年 6 月
李婕	图神经网络 数据安全	面向联邦图学习的类不平衡方法研究	王金艳	2025 年 6 月
杨汉钦	图神经网络 数据安全	无监督图神经网络的异常检测方法研究	王金艳	2025 年 6 月
杨柳	图神经网络 数据安全	图神经网络中的跨域成员推理攻击方法研究	王金艳	2026 年 6 月
郭辰豪	图神经网络	结构熵优化的差分隐私图	王金艳	2026 年 6 月